

UNIVERSIDAD POLITÉCNICA DE MADRID
Escuela Técnica Superior de Ingeniería de Sistemas
Informáticos



UNIVERSIDAD
POLITÉCNICA
DE MADRID



Máster
Deep Learning
Universidad Politécnica de Madrid

Trabajo Fin de Máster

Sistema LLM para análisis financiero histórico
mediante generación automática de código

MÁSTER DE FORMACIÓN PERMANENTE
EN DEEP LEARNING

Presentado por:

Carlos Ruiz Oyarzun

Bajo la dirección de:

Adrián Girón Jiménez

Alejandro Delgado Peribáñez

Madrid, 2026

Resumen

Este trabajo estudia el diseño de un sistema multiagente basado en modelos de lenguaje para realizar análisis financiero histórico a partir de consultas formuladas en lenguaje natural. El foco del proyecto no está en predecir el mercado, sino en organizar un flujo trazable en el que la petición se transforme en una estructura de datos interpretable, se validen los datos necesarios, se genere código ejecutable, se controle su ejecución y se redacte una respuesta final apoyada en evidencias.

La memoria queda preparada para documentar ese recorrido por etapas. En particular, se refuerzan la metodología, la descripción del flujo y el marco de evaluación, de manera que el trabajo final pueda explicar no solo si el sistema produce respuestas, sino también cómo llega a ellas, dónde falla y qué garantías ofrece cada bloque del proceso.

En esta versión, varias secciones se han dejado como plantilla guiada para completar conforme se implemente y evalúe el flujo definitivo. El objetivo es que la memoria final mantenga coherencia entre diseño, ejecución, resultados y limitaciones, y que cada afirmación importante pueda apoyarse en artefactos observables del sistema.

Palabras clave: análisis financiero histórico, modelos de lenguaje, generación de código, agentes LLM, ejecución controlada, trazabilidad.

Abstract

This work studies the design of a multi-agent language-model-based system for historical financial analysis from natural-language queries. Rather than predicting market behaviour, the project focuses on defining a traceable workflow in which a request is transformed into structured data, relevant market data are validated, executable code is produced, execution is controlled, and the final answer is grounded in observable evidence.

The dissertation has been prepared so that methodology, workflow description and evaluation can be developed rigorously as the final system is implemented. Several sections are therefore kept as guided templates, allowing the final document to explain not only whether the system works, but also how each stage contributes to robustness, traceability and controlled failure handling.

At this stage, the document provides a coherent structure for reporting the final project, with special emphasis on methodological justification, stage-by-stage analysis and evidence-based evaluation.

Keywords:

historical financial analysis, language models, code generation, LLM agents, traceability.

Índice general

Resumen	I
Abstract	II
Abreviaturas y acronimos	VIII
1. Introduccion	1
1.1. Contexto y definicion del problema	1
1.2. Motivacion	2
1.3. Objetivos	2
1.4. Alcance	3
1.5. Estructura de la memoria	3
2. Estado de la cuestion	4
2.1. Enfoque de la revision	4
2.2. Modelos de lenguaje y agentes financieros	4
2.3. Agentes, herramientas y orquestacion	5
2.4. Generacion y ejecucion controlada de codigo	5
2.5. Fiabilidad y evaluacion de sistemas generativos	6
2.6. Comparativa y posicionamiento de la propuesta	7
3. Material de trabajo y planteamiento experimental	8
3.1. Funcion de este capitulo	8
3.2. Origen y naturaleza del material de trabajo	8
3.3. Preguntas utiles para orientar este capitulo	8
3.4. Inventario del material	9
3.5. Casos y escenario experimental de partida	9
3.6. Criterio de redaccion recomendado	9
4. Metodologia	10
4.1. Funcion de este capitulo	10
4.2. Enfoque metodologico	10

4.3.	Preguntas guia para escribir bien la metodologia	10
4.3.1.	Sobre el objetivo de evaluacion	10
4.3.2.	Sobre la unidad de analisis	11
4.3.3.	Sobre el diseno experimental	11
4.3.4.	Sobre la evaluacion	11
4.3.5.	Sobre la validez del estudio	11
4.4.	Estructura recomendada para la metodologia final	12
4.4.1.	Pregunta de investigacion y objetivos evaluables	12
4.4.2.	Unidad de analisis	12
4.4.3.	Diseno experimental	12
4.4.4.	Protocolo de ejecucion	12
4.4.5.	Metricas de evaluacion	12
4.4.6.	Revision humana	12
4.4.7.	Amenazas a la validez	13
4.5.	Criterio de calidad para este capitulo	13
5.	Flujo multiagente del sistema	14
5.1.	Funcion de este capitulo	14
5.2.	Preguntas que debe responder el capitulo	14
5.3.	Vision general del flujo	15
5.4.	Entrada y estado compartido	15
5.4.1.	Entrada del sistema	15
5.4.2.	Estado compartido	16
5.5.	Flujo principal del sistema	16
5.5.1.	Parte de datos	16
5.5.2.	Analista y generador de codigo	16
5.5.3.	Validacion del codigo	17
5.5.4.	Validacion de ejecucion	17
5.5.5.	Interpretacion y respuesta final	17
5.6.	Subagentes de correccion y recuperacion	18
5.7.	Diseno de prompts y contratos de los agentes	18
5.8.	Trazabilidad y artefactos generados	19
5.9.	Decisiones de diseno	19
6.	Resultados y evaluacion	20
6.1.	Funcion de este capitulo	20
6.2.	Enfoque recomendado	20
6.3.	Preguntas que convendra responder mas adelante	20
6.4.	Plantilla de estructura futura	21
6.4.1.	Resultado global	21

6.4.2.	Lectura por grupos de casos	21
6.4.3.	Análisis por etapas	21
6.4.4.	Casos representativos	21
6.4.5.	Discusión crítica	21
7.	Limitaciones, aspectos éticos y reproducibilidad	22
7.1.	Función de este capítulo	22
7.2.	Limitaciones del estudio	22
7.3.	Aspectos éticos y uso responsable	22
7.4.	Reproducibilidad	22
7.5.	Preguntas de control	23
8.	Conclusiones y trabajo futuro	24
8.1.	Función de este capítulo	24
8.2.	Guía para las conclusiones	24
8.3.	Guía para el trabajo futuro	24
A.	Anexos	25
A.1.	Ejecución del sistema	25
A.1.1.	Preparación mínima	25
A.1.2.	Ejecución con ejemplos integrados	25
A.1.3.	Ejecución con una entrada JSON propia	26
A.1.4.	Salida y artefactos generados	26
A.2.	Configuración LLM y API	27
A.2.1.	Configuración recomendada	27
A.2.2.	Variables equivalentes admitidas	27
A.2.3.	Parámetros de generación	28
A.2.4.	Comprobaciones prácticas	28
A.3.	Notas para reproducibilidad	28

Índice de tablas

2.1. Comparacion entre los trabajos relacionados y la propuesta desarrollada.	7
3.1. Inventario inicial del material de trabajo.	9
4.1. Metricas previstas para la evaluacion del sistema.	12
5.1. Guia para documentar los prompts y contratos de los agentes.	18

Índice de figuras

5.1. Flujo multiagente de referencia para el desarrollo del sistema de analisis financiero.	15
--	----

Abreviaturas y acronimos

API Application Programming Interface.

CSV Comma-Separated Values.

ETF Exchange-Traded Fund.

LLM Large Language Model.

OHLCV Open, High, Low, Close, Adjusted Close y Volume.

RAG Retrieval-Augmented Generation.

UTC Coordinated Universal Time.

Capítulo 1

Introduccion

1.1. Contexto y definicion del problema

Los modelos de lenguaje de gran escala han ampliado de forma notable las posibilidades de interaccion con los sistemas informaticos. Ademas de producir texto, pueden interpretar instrucciones, proponer procedimientos y generar codigo ejecutable. Buena parte de este avance se apoya en la arquitectura Transformer y en el mecanismo de atencion, que constituyen una de las bases de los modelos de lenguaje actuales.

La capacidad de generar codigo resulta especialmente interesante en tareas de analisis de datos. Una consulta expresada en lenguaje natural puede transformarse en operaciones de carga, filtrado, calculo y presentacion de resultados. Sin embargo, esta flexibilidad introduce un problema de confianza: que el codigo sea plausible no significa que sea correcto, y que una respuesta este bien redactada no garantiza que respete los datos de partida.

Este problema cobra especial importancia en el ambito financiero. Incluso cuando el analisis se limita a informacion historica, una cifra incorrecta o una interpretacion poco prudente puede conducir a conclusiones equivocadas. Por ello, no basta con pedir al modelo que responda directamente a una consulta: tambien es necesario conocer que datos ha utilizado, que metricas ha calculado, que codigo ha ejecutado y que limitaciones presenta el resultado.

Este trabajo aborda el problema desde la integracion de sistemas, no desde el entrenamiento de un nuevo modelo. Para ello, se desarrolla un prototipo que recibe una consulta financiera y un conjunto de datos historicos almacenados en CSV, organiza el analisis mediante agentes LLM y mantiene los calculos dentro de un flujo programatico. El sistema separa la planificacion, la generacion de codigo y la interpretacion final, valida el codigo antes de ejecutarlo y conserva los principales artefactos de cada ejecucion.

1.2. Motivacion

El proyecto nace del interes por combinar tres ambitos que a menudo se estudian por separado: los modelos de lenguaje, la programacion para el analisis de datos y la interpretacion financiera. Los LLM permiten construir con rapidez interfaces capaces de entender peticiones diversas, pero esa misma facilidad puede ocultar errores cuando todo el proceso queda reducido a una unica respuesta generativa.

La motivacion principal es comprobar hasta que punto puede aprovecharse la flexibilidad del modelo sin renunciar a mecanismos basicos de control. En el sistema propuesto, el LLM decide como abordar la consulta y genera el codigo necesario, pero el resultado financiero procede de la ejecucion de ese codigo sobre datos locales. Esta separacion permite revisar tanto el planteamiento seguido como los calculos obtenidos.

Otro criterio importante es que los fallos sean visibles. Si el prototipo no puede generar codigo valido, la ejecucion no termina correctamente o la salida supera las capacidades del modelo, el sistema registra el problema y devuelve un error controlado. Este comportamiento resulta preferible a completar una respuesta con cifras no verificadas. La evaluacion mediante los casos de estudio definidos para el proyecto permite observar estos fallos, especialmente en los escenarios de mayor dificultad, e identificar en que parte del proceso se producen.

El prototipo se construyo de forma incremental, desde consultas sencillas hasta un flujo con tres agentes, validacion, reparacion y conservacion de evidencias.

1.3. Objetivos

El objetivo general del trabajo es disenar, implementar y evaluar un sistema basado en un modelo de lenguaje capaz de transformar consultas sobre datos financieros historicos en calculos ejecutables y respuestas trazables.

Los objetivos especificos son:

- Disenar una arquitectura modular que separe la planificacion, la generacion de codigo, su validacion, la ejecucion de los calculos y la elaboracion de la respuesta final.
- Desarrollar un flujo capaz de interpretar consultas con diferentes requisitos analiticos y determinar los datos, metricas y operaciones necesarios.
- Generar y ejecutar codigo Python adaptado a cada consulta, aplicando controles que limiten las operaciones permitidas.
- Garantizar la trazabilidad del proceso mediante la conservacion del plan, el codigo generado, los resultados estructurados y los registros de error.

- Generar respuestas financieras basadas exclusivamente en los calculos realizados, sin incorporar predicciones ni recomendaciones de inversion.
- Evaluar la capacidad del modelo de lenguaje para comprender y adaptarse a las tareas planteadas, generar codigo acorde con sus requisitos y redactar respuestas claras, precisas y fundamentadas.

1.4. Alcance

El sistema se limita al analisis historico y descriptivo de activos financieros a partir de datos descargados previamente y almacenados en ficheros CSV. Los casos utilizados incluyen acciones, indices, fondos cotizados, divisas, una materia prima y un criptoactivo, con diferentes periodos e intervalos temporales.

El prototipo no obtiene precios en tiempo real durante la ejecucion, no incorpora noticias ni informacion macroeconomica y tampoco realiza analisis fundamental. No pretende predecir movimientos futuros ni recomendar la compra o venta de activos. Estas restricciones responden al proposito del trabajo: evaluar una arquitectura LLM trazable, no construir un asesor financiero.

1.5. Estructura de la memoria

La memoria se organiza en torno a los tres bloques que mas peso tendran en el desarrollo del TFM: la metodologia, el flujo multiagente y la evaluacion del sistema. El Capitulo 2 revisa los trabajos previos y situa la propuesta dentro del estado de la cuestion. El Capitulo 3 resume el material de trabajo y el planteamiento experimental de partida.

El Capitulo 4 define la metodologia con la que se estudiara el sistema: unidad de analisis, protocolo de ejecucion, criterios de evaluacion y amenazas a la validez. El Capitulo 5 se reserva para el flujo multiagente del sistema y para la explicacion detallada de sus etapas, contratos, validaciones y rutas de recuperacion. El Capitulo 6 recogerá los resultados y la evaluacion final del proyecto.

Los ultimos capitulos se plantean de forma mas compacta. El Capitulo 7 reunira las limitaciones, los aspectos eticos y las condiciones de reproducibilidad, mientras que el Capitulo 8 cerrara la memoria con las conclusiones y el trabajo futuro. Por ultimo, los anexos conservaran solo la informacion operativa de apoyo que siga siendo util para ejecutar el sistema, documentar su configuracion LLM y describir los artefactos tecnicos que deja cada corrida.

Capítulo 2

Estado de la cuestion

2.1. Enfoque de la revision

Este capitulo situa el trabajo dentro del uso de modelos de lenguaje para el analisis financiero y la automatizacion de tareas de datos. No se pretende revisar todo el campo de la inteligencia artificial aplicada a las finanzas, sino centrarse en las lineas que sustentan el sistema desarrollado: los modelos especializados en este dominio, las arquitecturas basadas en agentes, el uso de herramientas externas, la generacion de codigo y la evaluacion de sistemas generativos.

El punto de partida es un modelo de pesos abiertos ya existente, identificado en este trabajo como `openai/gpt-oss-20b` e integrado en un flujo de trabajo controlado. Ante una consulta en lenguaje natural, el modelo interviene en la planificacion del analisis, la generacion de codigo Python y la redaccion de una respuesta basada en los resultados obtenidos al analizar datos historicos locales. Quedan fuera del alcance el entrenamiento de un modelo propio, la prediccion de precios y la toma autonoma de decisiones de inversion.

2.2. Modelos de lenguaje y agentes financieros

La aplicacion del procesamiento del lenguaje natural al ambito financiero es anterior a los modelos generativos actuales. FinBERT adapta la arquitectura BERT al lenguaje financiero y muestra la utilidad de los modelos especializados en tareas como el analisis de sentimiento. Posteriormente, BloombergGPT y FinGPT ampliaron esta linea mediante modelos entrenados o adaptados con noticias, documentacion corporativa y otros recursos propios del sector.

Estos trabajos muestran que el lenguaje financiero contiene vocabulario y relaciones que requieren una interpretacion cuidadosa. En este trabajo se adopta una perspectiva distinta: se utiliza `openai/gpt-oss-20b`, un modelo de pesos abiertos con cerca

de 21.000 millones de parametros totales que, gracias a su arquitectura de mezcla de expertos, activa aproximadamente 3.600 millones por cada token procesado. La denominación *20b* indica su escala aproximada, pero no constituye por si sola una medida de la calidad de las respuestas. El interes se centra en estudiar su integracion en un sistema verificable de analisis historico.

La evolucion de los LLM financieros tambien ha favorecido la aparicion de sistemas basados en agentes. FinRobot propone una arquitectura orientada a la investigacion y valoracion de empresas, mientras que TradingAgents distribuye tareas de analisis, debate y toma de decisiones de trading entre varios agentes. En ambos casos, el modelo deja de actuar unicamente como generador de texto y pasa a intervenir en un proceso compuesto por distintas responsabilidades.

2.3. Agentes, herramientas y orquestacion

Los sistemas basados en agentes permiten que un modelo vaya mas alla de la generacion de texto: puede utilizar herramientas y trabajar con los resultados de acciones externas. ReAct propone alternar razonamiento y actuacion para que el modelo observe las consecuencias de sus decisiones. Toolformer estudia como puede aprender a recurrir a herramientas cuando las necesita. Las revisiones sobre agentes basados en LLM describen esta evolucion como el paso de sistemas puramente conversacionales a arquitecturas capaces de planificar, actuar y utilizar observaciones del entorno.

Para coordinar estas tareas es necesario conservar la informacion producida durante la ejecucion. En la practica, esto exige mantener un estado compartido, definir etapas con responsabilidades separadas y establecer transiciones controladas entre validacion, generacion, ejecucion e interpretacion. Esta estructura resulta especialmente util cuando se combinan componentes generativos con comprobaciones programaticas.

El sistema adopta este patron mediante un recorrido definido de antemano. El modelo no selecciona libremente las herramientas ni altera el orden del proceso, y el estado compartido conserva la informacion de cada ejecucion sin mantener una memoria conversacional permanente. Los detalles de esta arquitectura se presentan mas adelante en los capitulos dedicados a la metodologia y al flujo multiagente del sistema.

2.4. Generacion y ejecucion controlada de codigo

La generacion automatica de codigo es una de las capacidades que mas ha impulsado el uso de los modelos de lenguaje en tareas tecnicas. El trabajo sobre Codex mostro que un modelo entrenado con grandes cantidades de codigo puede sintetizar programas a partir de descripciones en lenguaje natural y evaluarse con pruebas funcionales como HumanEval. En ciencia de datos, DS-1000 amplio esta linea con un banco de pruebas

basado en problemas mas cercanos a escenarios reales y apoyado en librerias habituales de analisis.

Estas investigaciones respaldan el uso de un LLM para traducir una consulta financiera en operaciones de carga, filtrado y calculo. Tambien ponen de manifiesto una limitacion fundamental: que un programa parezca correcto no implica que sea ejecutable, seguro o fiel a la peticion. Por ello, el codigo no se considera una respuesta final, sino un artefacto intermedio que debe superar varios controles.

Ejecutar codigo generado por un modelo introduce riesgos especificos. Los estudios sobre asistentes de programacion han mostrado que sus sugerencias pueden contener vulnerabilidades, incluso cuando parecen funcionales. Por este motivo, el codigo debe validarse antes de su ejecucion y limitarse a un conjunto restringido de operaciones.

La propuesta trata el codigo como un artefacto intermedio que debe respetar un contrato estructurado y superar controles antes de ejecutarse. Esta combinacion permite separar el calculo de su comunicacion, aunque no elimina todos los riesgos asociados a la ejecucion de codigo generado.

2.5. Fiabilidad y evaluacion de sistemas generativos

Una limitacion conocida de los modelos generativos es la produccion de respuestas plausibles que no se corresponden con la informacion disponible, fenomeno denominado habitualmente alucinacion. La generacion aumentada con recuperacion busca reducir este problema apoyando la respuesta en fuentes obtenidas de forma explicita. Aunque el sistema no incorpora recuperacion documental, sigue un principio de anclaje similar: la explicacion final debe basarse en datos locales, codigo ejecutado y resultados registrados.

Este anclaje es especialmente importante en el analisis financiero. Cuando una respuesta presenta datos de rentabilidad, volatilidad o drawdown, debe ser posible revisar tanto la informacion de partida como el procedimiento seguido. Tambien conviene separar con claridad la descripcion del comportamiento historico de cualquier prediccion o recomendacion. Conservar la consulta, el plan, el codigo, los resultados, los errores y la respuesta final no elimina la posibilidad de fallo, pero ayuda a localizarlo y valorar sus consecuencias.

La evaluacion de un sistema de estas caracteristicas no puede reducirse a una unica cifra. Los marcos de evaluacion amplios y transparentes defienden una lectura compuesta por distintos escenarios y metricas, para evitar que un resultado agregado oculte capacidades y limitaciones relevantes. En el caso del texto generado, tambien se ha senalado que las metricas automaticas tradicionales no siempre reflejan la calidad percibida durante una evaluacion humana.

Siguiendo estas ideas, la evaluacion combina indicadores tecnicos, una valoracion

cualitativa y revision humana. Esta aproximacion permite distinguir entre los fallos del flujo y las respuestas que, aun completandose, presentan problemas de pertinencia, fidelidad o claridad.

2.6. Comparativa y posicionamiento de la propuesta

La Tabla 2.1 resume las lineas revisadas y muestra como se relacionan con el sistema desarrollado. El objetivo concreto es integrar un modelo de lenguaje con generacion controlada de codigo y analisis reproducible de datos historicos.

Tabla 2.1: Comparacion entre los trabajos relacionados y la propuesta desarrollada.

Trabajo o linea	Aportacion principal	Relacion con este trabajo
FinBERT, BloombergGPT y FinGPT	Modelos entrenados o adaptados al lenguaje financiero.	Se centran en el modelo; la propuesta estudia la integracion controlada de openai/gpt-oss-20b en un flujo verificable.
FinRobot y TradingAgents	Agentes para investigacion, valoracion o trading.	Inspiran la separacion de responsabilidades, pero el sistema no toma decisiones de inversion ni actua sobre el mercado.
ReAct, Toolformer y arquitecturas de orquestacion	Uso de herramientas externas y coordinacion de pasos mediante observaciones y transiciones controladas.	Respaldan el uso de herramientas y un estado comun; aqui el recorrido esta fijado para favorecer el control.
Codex, DS-1000 y seguridad de codigo	Sintesis, evaluacion y riesgos del codigo producido por modelos.	Justifican la generacion de codigo bajo contrato y su validacion antes de ejecutarlo.
Alucinaciones y RAG	Estudio de respuestas no fieles y anclaje en fuentes externas.	La respuesta se apoya en los CSV locales y en los resultados obtenidos, aunque no se utiliza recuperacion documental.
HELM y G-Eval	Evaluacion multidimensional y calidad del texto generado.	Fundamentan la combinacion de indicadores tecnicos, dimensiones cualitativas y revision humana.

En conjunto, el trabajo ocupa una posicion intermedia entre un asistente puramente conversacional y un agente financiero autonomo. Un unico modelo planifica el analisis, genera el codigo y explica los resultados, mientras que las capas deterministas se encargan de la validacion, la ejecucion y el registro de artefactos. Esta separacion permite estudiar el valor practico del modelo sin atribuirle capacidades que no se han implementado ni evaluado.

Capítulo 3

Material de trabajo y planteamiento experimental

3.1. Funcion de este capitulo

Este capitulo debe situar al lector antes de entrar en la metodologia formal y antes de describir el flujo del sistema. Su papel es explicar con que material se va a trabajar, que tipo de consultas se quieren resolver y por que ese conjunto resulta adecuado para tensionar el nuevo TFM.

3.2. Origen y naturaleza del material de trabajo

Completar aqui el origen de los datos, el tipo de instrumentos incluidos, la razon de su seleccion y la forma en que se obtendran o congelaran para el proyecto. Conviene mantener esta seccion breve y muy clara.

3.3. Preguntas utiles para orientar este capitulo

1. ¿Que activos o instrumentos quieres incluir en el nuevo TFM y por que esos y no otros?
2. ¿Quieres priorizar variedad de clases de activo, realismo de las consultas o facilidad de reproducir el experimento?
3. ¿Que papel juegan los datos historicos descargados frente a la posible descarga automatica durante el flujo?
4. ¿Las consultas van a nacer de ejemplos cerrados, de una bateria definida o de escenarios abiertos controlados?

5. ¿Que hace que el conjunto de casos sea suficientemente representativo para defender el trabajo?

3.4. Inventario del material

Elemento	Tipo	Estado	Papel dentro del TFM
<i>Completar</i>	<i>Datos / casos / artefactos</i>	<i>Disponible / por construir</i>	<i>Completar</i>
<i>Completar</i>	<i>Datos / casos / artefactos</i>	<i>Disponible / por construir</i>	<i>Completar</i>
<i>Completar</i>	<i>Datos / casos / artefactos</i>	<i>Disponible / por construir</i>	<i>Completar</i>

Tabla 3.1: Inventario inicial del material de trabajo.

3.5. Casos y escenario experimental de partida

Completar aqui el tipo de consultas que quieres estudiar: consultas directas, comparativas, tecnicas, con restricciones de formato, con necesidad de descarga, con validaciones o con reparacion. La idea es anticipar la forma de la evaluacion sin entrar todavia en las metricas formales.

3.6. Criterio de redaccion recomendado

Cuando este capitulo quede cerrado, deberia responder con claridad a tres preguntas:

1. ¿Con que material concreto se construye el proyecto?
2. ¿Que tipo de casos o consultas se espera resolver?
3. ¿Por que ese punto de partida es suficiente para justificar el estudio?

Capítulo 4

Metodologia

4.1. Funcion de este capitulo

Este capitulo debe explicar como se va a estudiar el sistema y con que criterio se va a juzgar si el nuevo TFM funciona bien o no. No debe confundirse con la descripcion del flujo: aqui lo importante no es como esta construido el sistema, sino como se va a analizar de forma defendible.

4.2. Enfoque metodologico

Completar aqui la idea central del enfoque metodologico. Por ejemplo: desarrollo iterativo de un sistema multiagente, evaluacion empirica sobre casos de analisis financiero historico, combinacion de revision tecnica y lectura cualitativa de resultados, etc.

4.3. Preguntas guia para escribir bien la metodologia

4.3.1. Sobre el objetivo de evaluacion

1. ¿Que quieres demostrar exactamente con este TFM?
2. ¿Quieres demostrar viabilidad del flujo, robustez de la arquitectura, calidad de las respuestas o una combinacion de ellas?
3. ¿Que seria un buen resultado, pero no necesariamente una demostracion completa?
4. ¿Que afirmaciones no deberias hacer aunque el prototipo funcione bien?

4.3.2. Sobre la unidad de analisis

1. ¿Que vas a considerar como unidad de analisis principal: una consulta, una ejecucion completa, una etapa del flujo o un caso compuesto?
2. ¿Te interesa medir solo el resultado final o tambien el comportamiento intermedio de cada agente?
3. ¿Quieres analizar los fallos por etapa o solo por caso completo?

4.3.3. Sobre el diseno experimental

1. ¿Como vas a construir o seleccionar la bateria de consultas del nuevo TFM?
2. ¿Como vas a graduar la dificultad de los casos?
3. ¿Quieres hablar de complejidad de forma cualitativa sin imponer una etiqueta fija al sistema?
4. ¿Que tipos de consulta deben estar presentes para que el experimento sea creible?
5. ¿Que parte del flujo quieres tensionar de forma deliberada?

4.3.4. Sobre la evaluacion

1. ¿Como distinguiras entre exito tecnico del flujo y calidad real del analisis?
2. ¿Que metricas tecnicas quieres observar: completitud, tiempo, errores por etapa, reparaciones, trazas conservadas?
3. ¿Que dimensiones cualitativas quieres valorar: pertinencia de metricas, fidelidad de la interpretacion, prudencia, claridad?
4. ¿Habra revision humana? Si la hay, ¿con que rubrica o con que criterios?

4.3.5. Sobre la validez del estudio

1. ¿Que amenazas a la validez interna puede tener el experimento?
2. ¿Que limita la generalizacion del trabajo?
3. ¿Hasta que punto dependes del modelo concreto, de los prompts o del proveedor de inferencia?
4. ¿Como evitaras confundir una respuesta convincente con un resultado correcto?

4.4. Estructura recomendada para la metodologia final

4.4.1. Pregunta de investigacion y objetivos evaluables

Completar aqui la pregunta principal de investigacion y los objetivos que realmente puedan verificarse con el experimento.

4.4.2. Unidad de analisis

Completar aqui que se evalua exactamente en cada caso y por que esa unidad de analisis es adecuada para el TFM.

4.4.3. Diseno experimental

Completar aqui el numero de casos, su clasificacion, su dificultad y el razonamiento que justifica ese diseno. Si se habla de consultas mas simples o mas avanzadas, conviene que esa clasificacion se use solo como herramienta de evaluacion y no como una etiqueta explicita que el sistema reciba en la entrada.

4.4.4. Protocolo de ejecucion

Completar aqui como se lanza cada caso, que artefactos se conservan, que pasos del flujo deben completarse y como se registran errores, reparaciones y tiempos.

4.4.5. Metricas de evaluacion

Metrica	Tipo	Utilidad dentro de la evaluacion
Completar	Tecnica / cualitativa	Completar
Completar	Tecnica / cualitativa	Completar
Completar	Tecnica / cualitativa	Completar

Tabla 4.1: Metricas previstas para la evaluacion del sistema.

4.4.6. Revision humana

Completar aqui si habra rubricado manual, lectura comparada de respuestas, comprobacion de metricas o supervision por etapas.

4.4.7. Amenazas a la validez

Completar aqui sesgos de seleccion de casos, dependencia de configuracion, sensibilidad a prompts y cualquier otra limitacion metodologica importante.

4.5. Criterio de calidad para este capitulo

La metodologia final deberia permitir responder sin ambigüedad a cuatro cuestiones:

1. ¿Que se va a evaluar exactamente?
2. ¿Como se va a ejecutar esa evaluacion?
3. ¿Con que criterios se juzgara el sistema?
4. ¿Que limites tendra la interpretacion de los resultados?

Capítulo 5

Flujo multiagente del sistema

5.1. Funcion de este capitulo

Este capitulo es uno de los nucleos del nuevo TFM. Aqui no basta con decir que el sistema usa varios agentes: hace falta explicar con detalle como circula la informacion, que hace cada bloque, que controles existen y por que esa organizacion mejora la trazabilidad y la explicabilidad del analisis.

La idea central que conviene sostener en todo el capitulo es la siguiente: el valor del sistema no esta solo en producir una respuesta final, sino en hacerlo mediante un flujo auditable, con artefactos observables y con decisiones tecnicas que permitan entender que ha ocurrido en cada etapa.

5.2. Preguntas que debe responder el capitulo

1. ¿Que recibe exactamente el sistema y como se transforma esa entrada a lo largo del flujo?
2. ¿Que hace cada bloque principal y por que ese bloque es necesario?
3. ¿Que diferencia hay entre el flujo principal y los mecanismos de correccion?
4. ¿Que papel tienen los prompts como contrato operativo de los agentes?
5. ¿Que evidencias deja el sistema para poder reconstruir una ejecucion completa?
6. ¿Por que este flujo es mas explicable y controlable que una respuesta directa del LLM?
7. ¿Que decisiones de diseno ayudan a justificar luego la metodologia y la evaluacion?

5.3. Vision general del flujo

La Figura 5.1 se toma como referencia de alto nivel para el desarrollo del nuevo TFM. En ella se representa el recorrido completo desde la solicitud inicial del usuario hasta la respuesta final, incluyendo los agentes principales, los subagentes de correccion y los puntos de validacion mas relevantes.




Figura 5.1: Flujo multiagente de referencia para el desarrollo del sistema de analisis financiero.

Completar aqui una lectura global de la figura. Conviene describir el recorrido principal sin entrar todavia en todos los detalles tecnicos: que entra en el sistema, como se prepara la informacion, donde intervienen los agentes, en que puntos se valida el proceso y como se llega a la respuesta final. Este primer apartado debe servir para que el lector no se pierda cuando empieza el detalle del flujo.

Tambien conviene adelantar aqui dos ideas que luego se desarrollaran mejor: que la arquitectura busca separar responsabilidades y que esa separacion hace posible explicar mejor el comportamiento del sistema, detectar fallos y conservar evidencias del proceso.

5.4. Entrada y estado compartido

5.4.1. Entrada del sistema

Completar aqui que estructura recibe el sistema, que campos son obligatorios y que informacion no debe inferirse de forma libre. Conviene explicar si la entrada incluye

consulta, tickers, rango temporal, rutas de CSV, avisos y cualquier otro campo relevante. Tambien es importante dejar claro que el sistema no recibe una etiqueta previa de complejidad o profundidad de respuesta: los agentes deben inferirla a partir de la propia consulta y de sus requisitos.

En este apartado deberias poder explicar con comodidad por que la calidad de la entrada condiciona el resto del flujo y que errores se quieren evitar ya desde el primer momento.

5.4.2. Estado compartido

Completar aqui que informacion se va guardando durante la ejecucion y por que existe un estado compartido. Lo importante no es solo enumerar campos, sino justificar para que sirve cada grupo de informacion: entrada normalizada, plan analitico, codigo generado, resultados de ejecucion, respuesta final, errores y avisos.

Este apartado debe ayudarte a defender la trazabilidad del sistema. El lector tiene que entender que la respuesta final no aparece de forma opaca, sino que puede reconstruirse a partir de un historial estructurado de artefactos y transiciones.

5.5. Flujo principal del sistema

Este bloque debe contar el recorrido principal del sistema de forma limpia, sin detenerse todavia en todos los bucles de correccion. La idea es explicar que hace cada fase, que recibe, que produce y por que es necesaria dentro del flujo completo.

5.5.1. Parte de datos

Completar aqui todo el tramo inicial del flujo, desde la recepcion de la consulta hasta dejar preparada la informacion necesaria antes de entrar en el analisis principal. Puedes comentar normalizacion de la entrada, comprobacion de campos, seleccion o verificacion de CSV, coherencia entre consulta y datos disponibles y cualquier validacion temprana que reduzca errores posteriores.

Aqui conviene insistir en que esta fase no intenta resolver la consulta, sino preparar el contexto de trabajo con la mayor claridad posible. Desde el punto de vista de la explicabilidad, este bloque debe mostrar que el sistema no empieza a generar codigo sin haber delimitado antes con que datos puede trabajar y bajo que restricciones.

5.5.2. Analista y generador de codigo

Completar aqui como se transforma la peticion del usuario en un plan analitico y despues en un procedimiento ejecutable. Tiene sentido explicar juntos estos dos pa-

sos porque forman un mismo bloque conceptual: traducir una intencion expresada en lenguaje natural a una secuencia de calculos concreta.

En esta parte deberias comentar, al menos, que decide el agente analista, que restricciones recibe el generador de codigo, como se conecta el plan con el script final y que riesgos aparecen en esta traduccion. Tambien es un buen sitio para subrayar que el sistema no pide al LLM una conclusion financiera directa, sino un plan y un codigo trazable que luego sera sometido a controles.

5.5.3. Validacion del codigo

Completar aqui como se revisa el codigo antes de ejecutarlo. Interesa explicar que se comprueba, por que se comprueba y que tipo de errores o conductas se quieren bloquear: uso de operaciones no permitidas, incumplimiento del contrato de entrada o salida, accesos inseguros, estructura incorrecta o ausencia de controles minimos.

Este bloque es muy importante para defender el diseno del sistema. Desde el punto de vista de la memoria, aqui puedes explicar por que generar codigo no es suficiente y por que la validacion previa es una condicion necesaria para poder hablar de un flujo controlado.

5.5.4. Validacion de ejecucion

Completar aqui que ocurre una vez que el codigo ya se lanza: control del proceso, recogida de `stdout` y `stderr`, interpretacion del codigo de retorno, comprobacion de que la salida tenga el formato esperado y deteccion de fallos de calculo o inconsistencias.

Conviene dejar claro que ejecutar no equivale automaticamente a obtener un resultado valido. Esta fase debe mostrar que el sistema tambien controla lo que ocurre despues de la generacion de codigo y que la ejecucion se evalua como una evidencia tecnica, no solo como un paso ciego.

5.5.5. Interpretacion y respuesta final

Completar aqui como se transforma la salida estructurada en una respuesta final en espanol. Lo importante es explicar que esta etapa no recalcula ni inventa resultados, sino que interpreta lo ya obtenido y lo comunica de forma clara, prudente y ajustada a la consulta del usuario.

Este apartado es un buen lugar para destacar la explicabilidad externa del sistema: no solo interesa que el flujo sea auditable por dentro, sino que la respuesta final tambien sea comprensible para un lector humano y deje claros los resultados observados, su lectura y sus limitaciones.

5.6. Subagentes de correccion y recuperacion

Completar aqui el papel de los subagentes o mecanismos de reparacion. Conviene separarlos del flujo principal para que primero se entienda el recorrido base y despues se vea como reacciona el sistema cuando algo falla.

En este apartado deberias poder explicar cuando se activa cada correccion, que informacion recibe el subagente, que tipo de error intenta reparar y que criterio decide si el flujo continua o termina en error. Tambien interesa comentar si las reparaciones afectan al plan, al codigo, a la ejecucion o solo a una parte concreta del proceso.

Metodologicamente, esta seccion es importante porque muestra que el sistema no solo tiene una ruta ideal, sino tambien una estrategia controlada para gestionar fallos.

5.7. Diseno de prompts y contratos de los agentes

Este es el lugar adecuado para incluir los prompts dentro de la memoria principal. No conviene tratarlos como un anexo aislado, sino como parte del diseno operativo del sistema.

Completar aqui que objetivo tiene cada prompt, que entrada recibe cada agente, que salida se le exige y que restricciones guian su comportamiento. Puedes apoyarte en una tabla resumen y despues desarrollar los agentes mas importantes de forma narrativa.

Agente	Entrada principal	Salida esperada	Aspectos del prompt que conviene explicar
Agente de analisis	Completar	Completar	Objetivo, metricas, restricciones, estructura del plan.
Agente de codigo	Completar	Completar	Contrato tecnico, imports permitidos, formato de salida, limites de seguridad.
Agente de interpretacion	Completar	Completar	Uso exclusivo de resultados ejecutados, tono, prudencia y estructura de respuesta.
Subagentes de correccion	Completar	Completar	Tipo de error que reciben, alcance de la reparacion y limites de actuacion.

Tabla 5.1: Guia para documentar los prompts y contratos de los agentes.

En este bloque debes poder defender no solo que existen prompts distintos, sino por que estan separados y que gana el sistema con esa especializacion. Si incluyes fragmentos textuales, conviene que sean los que mejor revelan el contrato de cada agente y no necesariamente el prompt completo sin explicacion.

5.8. Trazabilidad y artefactos generados

Completar aquí que evidencias deja el sistema en cada ejecución. Este apartado es clave para justificar que el flujo es auditable y explicable. Lo importante no es enumerar solo ficheros, sino explicar que papel cumple cada artefacto dentro de la reconstrucción del proceso.

Puedes comentar, por ejemplo, la entrada normalizada, el plan analítico, el código generado, los logs de ejecución, la salida estructurada, los avisos, los errores y la respuesta final. Conviene explicar que gracias a estos artefactos es posible revisar por qué una respuesta fue correcta, insuficiente o fallida, y en qué punto del flujo se produjo el problema.

Este apartado conecta de forma natural con la metodología y con la evaluación posterior, porque deja claro que los resultados del TFM pueden defenderse con evidencias observables y no solo con impresiones subjetivas.

5.9. Decisiones de diseño

Completar aquí por qué se elige este flujo y no otro. Este apartado debe servir para justificar las principales elecciones de arquitectura: separación de responsabilidades, uso de varios agentes, validación previa a la ejecución, reparación controlada, anclaje a datos locales y conservación de artefactos.

No se trata de repetir la metodología, sino de defender las decisiones técnicas que hacen posible luego una evaluación seria del sistema. En otras palabras, aquí explicas por qué la arquitectura está pensada para producir un análisis más controlable, más explicable y más revisable que una respuesta directa generada de una sola vez por el modelo.

Capítulo 6

Resultados y evaluacion

6.1. Funcion de este capitulo

Este capitulo debe mostrar que ha ocurrido al ejecutar el sistema y como deben interpretarse esos resultados. Su objetivo no es solo presentar metricas, sino explicar que ensena la evaluacion sobre la robustez del flujo y sobre el valor real del TFM.

6.2. Enfoque recomendado

De momento conviene dejar este capitulo planteado, no cerrado. Cuando llegue el momento, la redaccion final deberia combinar:

1. una lectura global del rendimiento;
2. un analisis por tipo de caso o por grado de exigencia de la consulta;
3. una lectura por etapas del flujo;
4. una discusion de fallos, reparaciones y limites.

6.3. Preguntas que convendra responder mas adelante

1. ¿Que significa exactamente que el sistema haya completado bien un caso?
2. ¿Donde se concentran los errores: datos, planificacion, generacion, validacion, ejecucion o interpretacion?
3. ¿Que gana el sistema con los subagentes de correccion?
4. ¿Que tipos de consulta tensan mas la arquitectura?

5. ¿Que parte de los resultados respalda de verdad la tesis del trabajo?

6.4. Plantilla de estructura futura

6.4.1. Resultado global

Completar aqui el resumen global de la evaluacion cuando el sistema este implementado y probado.

6.4.2. Lectura por grupos de casos

Completar aqui la segmentacion de consultas que resulte mas util: por tipologia, por numero de restricciones, por formato de salida exigido o por etapa tensionada del flujo.

6.4.3. Analisis por etapas

Completar aqui el rendimiento observado en cada bloque del flujo.

6.4.4. Casos representativos

Completar aqui varios ejemplos que ilustren un caso sencillo, uno intermedio, uno complejo resuelto y un fallo informativo.

6.4.5. Discusion critica

Completar aqui que se ha demostrado, que no se ha demostrado y que mejoras quedarian priorizadas para una siguiente iteracion.

Capítulo 7

Limitaciones, aspectos eticos y reproducibilidad

7.1. Funcion de este capitulo

Este capitulo reúne tres elementos que no son el centro del TFM, pero si condicionan su interpretacion final: las limitaciones del estudio, el uso responsable del sistema y las condiciones para repetir el trabajo.

7.2. Limitaciones del estudio

Completar aqui limites de datos, dependencia del modelo, cobertura de casos, sensibilidad a prompts, dificultad de generalizacion y cualquier restriccion importante del sistema. Este es el lugar principal para reunir las limitaciones globales del TFM, aunque en metodologia y resultados tambien puede ser util comentar limites especificos de cada bloque.

7.3. Aspectos eticos y uso responsable

Completar aqui finalidad prevista, usos excluidos, supervision humana, limites del analisis historico y riesgos de ejecutar codigo generado o de sobrerinterpretar resultados financieros.

7.4. Reproducibilidad

Completar aqui lo necesario para repetir el trabajo: entorno, dependencias, datos, artefactos conservados, variables de entorno, pasos minimos de ejecucion y factores que pueden hacer variar el resultado.

7.5. Preguntas de control

1. ¿Que no debería concluir un lector a partir del sistema?
2. ¿Que necesita exactamente otra persona para repetir un caso?
3. ¿Que parte del resultado depende del flujo y que parte depende del modelo concreto?
4. ¿Que riesgos siguen abiertos aunque el sistema funcione?

Capítulo 8

Conclusiones y trabajo futuro

8.1. Funcion de este capitulo

La conclusion final debe recoger la aportacion principal del TFM con una formulacion clara y defendible. No conviene que sea una repeticion de capitulos anteriores ni una lista dispersa de ideas futuras.

8.2. Guia para las conclusiones

Completar aqui, al final del proyecto, una sintesis que responda a estas preguntas:

1. ¿Que problema has abordado realmente?
2. ¿Que has conseguido demostrar?
3. ¿Que evidencia es la mas importante para sostener esa afirmacion?
4. ¿Que limite obliga a interpretar el resultado con prudencia?

8.3. Guia para el trabajo futuro

Completar aqui las siguientes lineas de trabajo priorizadas: mejoras del flujo, robustez, validacion, ampliacion de casos, comparativas con otras soluciones y posible evolucion del sistema.

Apéndice A

Anexos

A.1. Ejecucion del sistema

Este anexo conserva solo la informacion operativa que sigue siendo util para ejecutar y defender la version actual del proyecto. El punto de entrada principal es `run_mvp.py`, que recibe una consulta financiera estructurada, construye el workflow multiagente y devuelve un JSON final con el estado completo de la ejecucion.

A.1.1. Preparacion minima

Antes de lanzar una ejecucion conviene comprobar cuatro condiciones:

1. que el entorno Python tenga instaladas las dependencias del proyecto;
2. que el fichero `.env` contenga una configuracion LLM valida;
3. que los CSV historicos existan en `data/raw`;
4. que la consulta de entrada incluya las rutas reales a esos CSV.

Una instalacion minima puede hacerse con:

```
python -m venv venv
venv\Scripts\activate
pip install -r requirements.txt
```

A.1.2. Ejecucion con ejemplos integrados

El proyecto incluye varios casos ya preparados en `src/examples/sample_inputs.py`. Cada uno contiene la consulta, los tickers y las rutas locales a los datos necesarios. La forma mas simple de comprobar el sistema es ejecutar uno de esos ejemplos:

```
python run_mvp.py --example growth_nvda
python run_mvp.py --example returns_qqq_spy
python run_mvp.py --example complex_nvda_growth_report
```

Esta vía es la más útil para una primera validación, porque evita errores de formato en la entrada y permite comprobar el flujo de extremo a extremo con casos ya definidos dentro del repositorio.

A.1.3. Ejecución con una entrada JSON propia

También es posible lanzar el sistema con un fichero JSON preparado manualmente:

```
python run_mvp.py --input-json ruta\al\caso.json
```

La estructura mínima esperada es la siguiente:

```
{
  "query": "Analiza los retornos de QQQ y SPY en 2024",
  "tickers": ["QQQ", "SPY"],
  "csv_paths": [
    "C:/ruta/al/repositorio/data/raw/qqq_y_spy_desde_20240101_hasta_20241231.csv"
  ],
  "start": "2024-01-01",
  "end": "2024-12-31",
  "period": null,
  "interval": "1d",
  "needs_clarification": false,
  "warnings": []
}
```

Los campos `query`, `tickers` y `csv_paths` son los que definen el caso de forma más directa. El resto de atributos ayudan a restringir el periodo, la granularidad temporal y las advertencias que se quieran conservar desde la entrada.

A.1.4. Salida y artefactos generados

La ejecución imprime por consola un JSON con el estado final del workflow. Ese estado incluye, entre otros elementos:

- la consulta original y su forma normalizada;
- el plan analítico generado por el agente planificador;
- el código Python producido para el cálculo;
- la salida estructurada de la ejecución;

- la respuesta final redactada para el usuario;
- el estado de la ejecucion, los avisos y los posibles errores.

Ademas, el sistema conserva artefactos intermedios en dos carpetas:

- `results/code`, con el codigo generado en cada ejecucion;
- `results/logs`, con el payload enviado al ejecutor y los ficheros de `stdout` y `stderr`.

Esta conservacion resulta util tanto para depurar fallos como para defender metodologicamente la trazabilidad del flujo en la memoria.

A.2. Configuracion LLM y API

La aplicacion utiliza un endpoint compatible con OpenAI Chat Completions. En la configuracion actual, el modelo `openai/gpt-oss-20b` se sirve a traves de `vLLM`, aunque el codigo acepta varias familias de variables de entorno equivalentes.

A.2.1. Configuracion recomendada

La forma mas directa de configurar el sistema es declarar en `.env`:

```
LLM_PROVIDER=openai-compatible
VLLM_BASE_URL=https://servidor-vllm.example/v1
VLLM_API_KEY=pegar_aqui_la_clave
VLLM_MODEL=openai/gpt-oss-20b
```

A.2.2. Variables equivalentes admitidas

El codigo reconoce tres familias de nombres para base URL, clave y modelo:

- familia `VLLM_*`: `VLLM_BASE_URL`, `VLLM_API_KEY`, `VLLM_MODEL`;
- familia `LLM_*`: `LLM_BASE_URL`, `LLM_API_KEY`, `LLM_MODEL`;
- familia `OPENAI_*`: `OPENAI_BASE_URL`, `OPENAI_API_KEY`, `OPENAI_MODEL`.

La resolucion de configuracion prioriza primero los valores `VLLM_*`, despues los valores genericos `LLM_*` y finalmente los alias `OPENAI_*`.

A.2.3. Parametros de generacion

Tambien pueden ajustarse los parametros principales del cliente:

```
LLM_TEMPERATURE=0.1  
LLM_MAX_TOKENS=4096  
LLM_TIMEOUT_SECONDS=120  
OPENAI_VERIFY_SSL=true
```

Estos valores controlan la temperatura de generacion, el maximo de tokens de salida, el tiempo de espera del cliente y la verificacion SSL del endpoint remoto.

A.2.4. Comprobaciones practicas

Si la configuracion es correcta, una ejecucion con `run_mvp.py` debe completar el flujo sin necesidad de descargar datos externos. Si la clave no esta definida o contiene un valor de ejemplo, el sistema no intenta llamar al modelo y devuelve un error de configuracion explicito.

A.3. Notas para reproducibilidad

De cara a la redaccion final de la memoria, este anexo sirve como referencia corta de reproduccion operativa. Para repetir un caso hacen falta el mismo codigo, los mismos CSV, una configuracion equivalente del modelo y acceso a un endpoint compatible con OpenAI. Si alguno de estos elementos cambia, el comportamiento del sistema puede variar incluso aunque la arquitectura general siga siendo la misma.