

Análisis de la Eficacia de Tratamientos Farmacológicos para la Depresión Mayor a través de Minería de Datos de Abstracts de PubMed



Universitat Oberta
de Catalunya

Alejandro Delgado Peribáñez

Machine Learning

Máster en Bioinformática y Bioestadística

Nombre del director/a de TF:
Romina Astrid Rebrij

Nombre del/de la PRA:
Agnès Pérez Millán

4 de junio de 2025



Esta obra esta sujeta a una licencia de Reconocimiento
<https://creativecommons.org/licenses/by-nc/3.0/es/>

Ficha Del Trabajo Final

Título del trabajo:	Análisis de la Eficacia de Tratamientos Farmacológicos para la Depresión Mayor a través de Minería de Datos de Abstracts de PubMed
Nombre del autor/a:	Alejandro Delgado Peribáñez
Nombre del director/a de TF:	Romina Astrid Rebrij
Nombre del/de la PRA:	Agnès Pérez Millán
Fecha de entrega:	4 de junio de 2025
Titulación o programa:	Máster en Bioinformática y Bioestadística
Área del trabajo final:	Machine Learning
Idioma del trabajo:	Castellano
Palabras clave:	Depresión mayor, Tratamientos farmacológicos, Minería de datos, Procesamiento del lenguaje natural, PubMed, Reconocimiento de entidades biomédicas (NER), Búsqueda semántica, Chatbot, BioGPT, MongoDB

Resumen del trabajo

Este trabajo presenta una aplicación web diseñada para analizar la eficacia de tratamientos farmacológicos para la depresión mayor mediante minería de datos en abstracts de PubMed. La aplicación integra técnicas avanzadas de procesamiento del lenguaje natural (PLN), como el reconocimiento de entidades biomédicas (NER) y la búsqueda semántica, para identificar patrones y tendencias en el uso de medicamentos. Los abstracts son extraídos y almacenados en una base de datos MongoDB, donde se aplican modelos ajustados de BioMedBERT para identificar entidades como fármacos y enfermedades. Los resultados se presentan a través de una interfaz web interactiva desarrollada en Streamlit, que permite a los usuarios explorar las entidades identificadas y realizar análisis de co-ocurrencias. Además, la aplicación incluye un chatbot basado en BioGPT, que responde preguntas sobre los tratamientos analizados. Este enfoque proporciona a los investigadores y profesionales de la salud una herramienta intuitiva para explorar de manera eficiente la literatura biomédica y obtener información relevante sobre la efectividad de diferentes terapias para la depresión mayor.

Abstract

This work presents a web application designed to analyze the effectiveness of pharmacological treatments for major depression through data mining of PubMed abstracts. The application integrates advanced natural language processing (NLP) techniques, such as biomedical named entity recognition (NER) and semantic search, to identify patterns and trends in the use of medications. Abstracts are extracted and stored in a MongoDB database, where BioMedBERT fine-tuned models are applied to identify entities such as drugs and diseases. The results are presented through an interactive web interface developed with Streamlit, allowing users to explore identified entities and perform co-occurrence analysis. Additionally, the application includes a BioGPT-based chatbot that answers questions about the analyzed treatments. This approach provides researchers and healthcare professionals with an intuitive tool to efficiently explore biomedical literature and obtain relevant information on the effectiveness of different therapies for major depression.

Índice general

1. Introducción	9
1.1. Contexto y Justificación del Trabajo	9
1.2. Impacto en Sostenibilidad, Ética y Diversidad	10
1.2.1. Impacto en Sostenibilidad	10
1.2.2. Impacto Ético y Social	11
1.2.3. Impacto en Diversidad y Derechos Humanos	11
1.3. Objetivos del Trabajo	12
1.3.1. Objetivos Generales	12
1.3.2. Objetivos Específicos	12
1.4. Enfoque y Método	12
1.4.1. Estrategias Consideradas	13
1.4.2. Metodología Elegida	13
1.4.3. Herramientas y Tecnologías Empleadas	14
1.5. Planificación y Cronograma	15
1.5.1. Tareas y Duración	15
1.5.2. Hitos Clave	15
1.5.3. Identificación y Mitigación de Riesgos	16
2. Estado del Arte	17
2.1. Depresión mayor: impacto y tratamientos farmacológicos	17
2.2. Bases de datos biomédicas y PubMed	17
2.3. Procesamiento de Lenguaje Natural en biomedicina	18
2.4. Modelos biomédicos preentrenados (BioBERT, PubMedBERT, BioMedBERT)	18
2.5. Aplicaciones existentes de minería de textos biomédicos	18
2.6. Justificación del presente trabajo	19
3. Materiales y métodos	20
3.1. Diseño general del trabajo	20
3.2. Estructura del proyecto y materiales empleados	20
3.3. Metodología seguida	21
3.4. Decisiones clave y criterios adoptados	22
3.5. Productos obtenidos	22
3.6. Infraestructura y entorno de desarrollo	23

4. Resultados	24
4.1. Extracción y almacenamiento de datos	24
4.2. Procesamiento de entidades biomédicas	26
4.3. Análisis agregado de la literatura	26
4.4. Exploración semántica de literatura	31
4.5. Caso clínico interactivo	33
4.6. Asistente clínico con inteligencia artificial	35
4.6.1. Comparación con herramientas similares	37
5. Conclusiones y trabajos futuros	39
5.1. Conclusiones	39
5.2. Seguimiento de la planificación	40
5.3. Líneas de trabajo futuro	40
6. Glosario	42
Bibliografía	44
7. Anexos	48

Índice de figuras

4.1. Query utilizada para recuperar ensayos clínicos sobre tratamientos para la depresión en PubMed.	25
4.2. Principales fármacos mencionados en la literatura analizada.	26
4.3. Ejemplos de co-ocurrencias entre fármacos y resultados clínicos.	27
4.4. Mapa de calor de co-ocurrencias entre tratamientos y resultados clínicos.	28
4.5. Número de menciones anuales de tratamientos farmacológicos en los abstracts.	29
4.6. Comparativa temporal entre sertralina y fluoxetina.	29
4.7. Red semántica de tratamientos y resultados clínicos.	30
4.8. Subgrafos de relaciones de sertralina (izquierda) y fluoxetina (derecha).	31
4.9. Resultado de búsqueda semántica sobre la eficacia de la sertralina en pacientes de edad avanzada.	32
4.10. Ficha detallada del artículo seleccionado por similitud semántica. Incluye resumen automático, entidades NER y acceso a PubMed.	33
4.11. Resumen estadístico y ejemplos clínicos sobre sertralina.	34
4.12. Resumen estadístico y ejemplos clínicos sobre fluoxetina.	34
4.13. Ejemplo de respuesta generada sobre los efectos clínicos de la sertralina.	36
4.14. Ejemplo de respuesta generada sobre la tasa de remisión de fluoxetina.	36
4.15. Respuesta del asistente clínico sobre los efectos adversos de la sertralina.	37

Índice de cuadros

6.1. Tabla de acrónimos utilizados en el documento.	44
---	----

Capítulo 1

Introducción

La depresión mayor es uno de los trastornos mentales más comunes y debilitantes a nivel mundial [1], afectando a millones de personas y generando una carga significativa para los sistemas de salud. A pesar de la existencia de múltiples opciones terapéuticas, la respuesta a los tratamientos farmacológicos varía considerablemente entre pacientes, lo que plantea la necesidad de enfoques basados en evidencia para optimizar la selección de terapias.

En este Trabajo de Fin de Máster (TFM), se desarrolló una aplicación web que aplica técnicas avanzadas de Procesamiento del Lenguaje Natural (PLN) y minería de datos para analizar la eficacia de tratamientos farmacológicos para la depresión mayor. Utilizando abstracts de la base de datos PubMed, la aplicación permite identificar patrones y tendencias en la literatura biomédica, proporcionando a los investigadores y profesionales de la salud una herramienta interactiva para explorar información relevante y fundamentar decisiones clínicas.

El proyecto combina tecnologías como el reconocimiento de entidades biomédicas (NER), búsqueda semántica y un chatbot conversacional basado en BioGPT, facilitando el acceso a conocimientos científicos de manera intuitiva y eficiente. Esta solución ofrece un enfoque automatizado y dinámico para la revisión de literatura científica, optimizando el análisis y la interpretación de los resultados.

1.1. Contexto y Justificación del Trabajo

La depresión mayor es uno de los trastornos psiquiátricos más prevalentes a nivel mundial, afectando aproximadamente a 280 millones de personas, según la Organización Mundial de la Salud (OMS) [1]. Se caracteriza por episodios prolongados de tristeza, pérdida de interés o placer en actividades cotidianas, fatiga y dificultad para concentrarse, entre otros síntomas [2]. Además de su impacto en la calidad de vida de los pacientes, este trastorno supone una carga económica y social significativa, reflejada en la pérdida de productividad laboral y en los costes relacionados con tratamientos prolongados [3].

El abordaje terapéutico de la depresión mayor incluye diversas estrategias farmacológicas, como inhibidores selectivos de la recaptación de serotonina (ISRS), antidepresivos tricíclicos y moduladores de la dopamina, entre otros [4]. Sin embargo, la respuesta a estos tratamientos varía ampliamente entre los pacientes. Estudios clínicos han indicado que hasta un 30 % de los pacientes no responden a la primera línea de tratamiento, subrayando la necesidad de enfoques más personalizados para la selección de terapias efectivas [5].

Actualmente, la comunidad científica dispone de grandes volúmenes de datos en bases biomédicas como PubMed [6], que contienen información detallada sobre ensayos clínicos, estudios de caso y metaanálisis en torno a la eficacia de diferentes tratamientos para la depresión mayor. No obstante, la revisión y el análisis manual de esta información resultan inviables debido al crecimiento exponencial de publicaciones científicas.

En este contexto, las técnicas de minería de datos y el Procesamiento del Lenguaje Natural (PLN) ofrecen soluciones innovadoras para automatizar la identificación de patrones en la literatura biomédica [7, 8]. Modelos avanzados de lenguaje entrenados en el ámbito biomédico, como *BioBERT* o *BioMedBERT*, permiten extraer información relevante de los resúmenes de artículos científicos, facilitando así la identificación de tratamientos potencialmente eficaces para distintos subgrupos de pacientes [9, 10].

Este Trabajo de Fin de Máster presenta una aplicación web que integra estas tecnologías para analizar y visualizar tendencias en la eficacia de tratamientos farmacológicos para la depresión mayor. Este enfoque proporciona a investigadores y profesionales de la salud acceso a información sintetizada y basada en evidencia, optimizando la toma de decisiones en el ámbito clínico.

1.2. Impacto en Sostenibilidad, Ética y Diversidad

El presente trabajo tiene un impacto significativo en tres dimensiones clave: sostenibilidad, ética y responsabilidad social, y diversidad. A continuación, se detallan los aspectos relevantes en cada una de estas áreas.

1.2.1. Impacto en Sostenibilidad

Este TFM se alinea con los Objetivos de Desarrollo Sostenible (ODS) propuestos por la Organización de las Naciones Unidas [11], particularmente con el ODS 9 (Industria, Innovación e Infraestructura) y el ODS 12 (Producción y Consumo Responsables). Su impacto en sostenibilidad se refleja en:

- **Uso eficiente de datos:** Se reutilizan datos ya existentes en la base de datos de PubMed, lo que evita la necesidad de generar nuevos estudios experimentales y reduce el consumo de recursos.
- **Reducción de la huella ambiental:** Al tratarse de un proyecto de análisis de datos basado en computación, no requiere experimentación con materiales físicos, lo que elimina la producción de desechos y el consumo de reactivos químicos.
- **Optimización de recursos computacionales:** Se han aplicado técnicas eficientes en el procesamiento de datos, minimizando el uso de recursos computacionales innecesarios y favoreciendo un consumo energético responsable.

1.2.2. Impacto Ético y Social

El impacto ético-social del TFM está vinculado, principalmente, al **ODS 3 (Salud y Bienestar)** [1], dado que la investigación se centra en la identificación de tratamientos farmacológicos eficaces para la depresión mayor. Los aspectos clave son:

- **Transparencia y acceso a la información científica:** La aplicación web facilita la consulta de estudios de manera estructurada, lo que contribuye a que la comunidad médica y los pacientes tomen decisiones informadas sobre los diferentes tratamientos.
- **Respeto por la privacidad y derechos de autor:** Se ha garantizado que los datos utilizados cumplan con las normativas de propiedad intelectual y privacidad, sin infringir derechos de los autores originales de las publicaciones científicas.
- **Apoyo a la investigación médica:** La automatización en la extracción de información reduce la carga de trabajo para investigadores, acelerando la identificación de tratamientos más efectivos para distintos perfiles de pacientes y contribuyendo a la mejora en la atención sanitaria.

1.2.3. Impacto en Diversidad y Derechos Humanos

Este TFM tiene un impacto positivo en la diversidad al promover la equidad en el acceso a información sobre tratamientos, en línea con el **ODS 5 (Igualdad de Género)** y el **ODS 10 (Reducción de Desigualdades)**. Se han considerado los siguientes aspectos:

- **Inclusión de estudios en poblaciones diversas:** Se analizaron investigaciones con datos de distintos grupos poblacionales para evaluar posibles sesgos en la investigación biomédica y garantizar que los resultados contemplen una variedad de perfiles de pacientes.
- **Accesibilidad de la aplicación:** Se aplicaron principios de diseño accesible para asegurar que personas con discapacidad puedan utilizar la herramienta sin barreras tecnológicas.
- **Lenguaje inclusivo y neutral:** Se ha evitado el uso de sesgos de género o exclusión en la presentación de resultados, procurando una comunicación científica accesible para todos los públicos.

En conjunto, el **impacto de este TFM** en materia de sostenibilidad, ética y diversidad refuerza su valor como contribución significativa a la ciencia abierta y a la equidad en el acceso a información biomédica relevante, alineándose con los ODS que promueven la **salud y el bienestar** (ODS 3), el **consumo y la producción responsables** (ODS 12), la **innovación** (ODS 9), así como la **igualdad de género** (ODS 5) y la **reducción de desigualdades** (ODS 10).

1.3. Objetivos del Trabajo

1.3.1. Objetivos Generales

- Desarrollar una aplicación web basada en modelos de Procesamiento de Lenguaje Natural (PLN) para analizar y extraer información relevante de abstracts científicos en PubMed sobre tratamientos farmacológicos para la depresión mayor.
- Aplicar técnicas de minería de datos y aprendizaje automático con el fin de identificar patrones en la eficacia de los tratamientos farmacológicos empleados en la depresión mayor.
- Ofrecer una herramienta accesible e interactiva para la visualización de resultados y la consulta de información relevante por parte de la comunidad médica y científica.

1.3.2. Objetivos Específicos

- Recopilar y preprocesar abstracts de artículos científicos utilizando la API de PubMed, asegurando la calidad y relevancia de los datos.
- Aplicar modelos avanzados de PLN, como BiomedBERT[10], para la extracción y clasificación de información clave sobre la eficacia de los tratamientos.
- Utilizar técnicas de minería de datos para analizar tendencias en la eficacia de los tratamientos según variables como el perfil de los pacientes y los criterios de éxito.
- Desarrollar una interfaz web intuitiva que permita la exploración interactiva de los resultados obtenidos, asegurando accesibilidad y facilidad de uso.
- Integrar un chatbot basado en inteligencia artificial capaz de responder consultas sobre la información extraída y asistir a los usuarios en la interpretación de los resultados.
- Incorporar un enfoque de Recuperación Aumentada con Generación (RAG) [12], empleando la librería **LangChain** [13], para mejorar la precisión de la información recuperada y proporcionar respuestas más contextualizadas a través del chatbot.
- Validar la precisión y utilidad de la aplicación mediante pruebas realizadas con expertos en psiquiatría y farmacología.

1.4. Enfoque y Método

Para alcanzar los objetivos planteados, se analizaron distintas estrategias metodológicas. A continuación, se describen las opciones consideradas y se justifica la elección de la metodología finalmente aplicada en este trabajo.

1.4.1. Estrategias Consideradas

- **Revisión manual de literatura científica:** Implicaba analizar de forma manual cada artículo relevante en PubMed para extraer conclusiones sobre la eficacia de los tratamientos. Sin embargo, esta metodología resultó inviable debido al volumen de publicaciones científicas disponibles.
- **Uso de técnicas tradicionales de análisis de datos:** Podían emplearse métodos estadísticos convencionales sobre datos estructurados de estudios previos. No obstante, la mayor parte de la información relevante se encuentra en texto no estructurado, lo que limitaba esta opción.
- **Aplicación de PLN y aprendizaje automático:** Permitía la extracción automática de información relevante desde textos científicos, así como la identificación de patrones en la eficacia de los tratamientos. Esta estrategia ofrecía mayor escalabilidad y precisión.

1.4.2. Metodología Elegida

Se aplicaron técnicas avanzadas de Procesamiento del Lenguaje Natural (PLN), Recuperación Aumentada con Generación (RAG) [12] y minería de datos para analizar los abstracts de PubMed, debido a sus ventajas en la extracción y análisis de grandes volúmenes de datos no estructurados. La metodología se organizó en los siguientes pasos:

1. **Extracción de datos:** Se obtuvieron abstracts mediante la API de PubMed, utilizando consultas específicas orientadas a estudios sobre depresión mayor y tratamientos farmacológicos.
2. **Preprocesamiento de textos:** Se realizó limpieza y normalización de los textos, incluyendo tokenización, eliminación de caracteres especiales y segmentación de abstracts extensos.
3. **Reconocimiento de Entidades Biomédicas (NER):** Se aplicaron modelos preentrenados como BioMedBERT[10] para identificar entidades clave (fármacos, enfermedades, organismos) en los textos, almacenando las anotaciones en una base de datos MongoDB.
4. **Generación de Embeddings y Búsqueda Semántica:** Se implementó un índice de búsqueda semántica con FAISS para permitir consultas contextuales sobre los abstracts procesados.
5. **Minería de datos y análisis de tendencias:** Se identificaron patrones y relaciones entre entidades biomédicas mediante análisis de co-ocurrencias y visualización de tendencias en los tratamientos.
6. **Desarrollo de interfaz web:** Se creó una aplicación en Streamlit [14] que permite a los usuarios consultar, explorar y analizar los abstracts y sus anotaciones.

7. **Chatbot clínico con arquitectura RAG:** Se implementó un chatbot que emplea una arquitectura Retrieval-Augmented Generation (RAG), combinando recuperación semántica de abstracts biomédicos y generación de respuestas mediante modelos especializados (Bio-ClinicalBERT y BioGPT) , todo orquestado con LangChain.
8. **Validación y evaluación:** Se realizaron pruebas con expertos en salud mental para evaluar la precisión, utilidad y facilidad de uso de la herramienta.

Esta metodología permitió abordar el problema de forma eficiente, escalable y con rigor científico, asegurando la obtención de resultados relevantes para la toma de decisiones en contextos clínicos y de investigación.

1.4.3. Herramientas y Tecnologías Empleadas

Para implementar la metodología descrita, se optó por el **lenguaje de programación Python**, dada su amplia adopción en proyectos de minería de datos y Procesamiento del Lenguaje Natural (PLN)[15]. En concreto:

- **Frameworks de PLN y ML:** Se emplearon librerías avanzadas como *Transformers* de Hugging Face (incluyendo modelos preentrenados como BioMedBERT y BioGPT [10, 16]), además de bibliotecas de apoyo como *spaCy*, *Pandas*, *Scikit-learn* y *nlTK*.
- **Base de datos:** Los abstracts y las anotaciones de entidades se almacenaron en una base de datos **MongoDB**, que permite un acceso rápido y flexible a la información procesada.
- **Framework para la aplicación web:** La interfaz fue desarrollada en *Streamlit*, permitiendo una creación ágil de aplicaciones web interactivas y ofreciendo una experiencia de usuario amigable.
- **Búsqueda semántica y embeddings:** Se implementó un sistema de búsqueda semántica basado en *FAISS* (Facebook AI Similarity Search) [17], lo que permite realizar consultas contextuales sobre los abstracts y acceder a información relevante de forma eficiente.
- **Chatbot conversacional:** Se integró un chatbot basado en *BioGPT*, capaz de responder preguntas de manera contextual utilizando un modelo de lenguaje biomédico ajustado.
- **Control de versiones y repositorio:** El proyecto fue gestionado con *Git*, y el código se almacenó en un **repositorio privado de GitHub**, lo que garantizó el control de versiones y facilitó la colaboración.
- **Herramientas de documentación:** La documentación del código y la lógica del proyecto se realizó directamente en el código fuente (mediante docstrings y comentarios) y en archivos *Markdown*, facilitando su comprensión y mantenibilidad.

El uso de estas tecnologías, junto con la aplicación de buenas prácticas de programación, aseguró la reproducibilidad y escalabilidad del proyecto, así como la posibilidad de futuras mejoras o colaboraciones con la comunidad científica.

1.5. Planificación y Cronograma

Para garantizar la correcta ejecución del proyecto, se definió una planificación detallada que desglosa las tareas necesarias para alcanzar los objetivos planteados. El trabajo se organizó en cuatro fases principales, correspondientes a las entregas (PECs), distribuyendo las tareas de forma progresiva y continua.

1.5.1. Tareas y Duración

- **Semana 1-2 (PEC1):** Definición y planificación del trabajo. Esta fase incluyó la redacción de la propuesta del proyecto, la identificación de objetivos, el diseño del flujo de trabajo y la configuración inicial del entorno de desarrollo.
- **Semana 3-6 (PEC2):** Desarrollo de la primera fase, que abarcó la revisión bibliográfica, la extracción de datos desde PubMed mediante su API y el preprocesamiento de abstracts (limpieza, normalización y segmentación). Esta etapa garantizó que los datos estuvieran preparados para el análisis.
- **Semana 7-11 (PEC3):** Desarrollo de la segunda fase, centrada en la implementación de modelos de Reconocimiento de Entidades Biomédicas (NER) utilizando BioMed-BERT[10]. Además, se desarrollaron scripts de minería de datos para analizar patrones en los textos y se preparó el backend de la aplicación.
- **Semana 12-15 (PEC4):** Desarrollo de la interfaz web en Streamlit, con funcionalidades para visualizar resultados y realizar consultas. Se integró un chatbot conversacional basado en BioGPT y se implementaron las capacidades de búsqueda semántica. También se redactó la memoria final, se realizaron pruebas del sistema y se efectuaron ajustes para su correcto funcionamiento.
- **Semana 15 (Cierre):** Validación y pruebas finales, ajustes finales y entrega del TFM.

1.5.2. Hitos Clave

- **Hito 1 (Semana 2):** Finalización de la definición y planificación del trabajo (PEC1), con objetivos claros y diseño del flujo de trabajo.
- **Hito 2 (Semana 6):** Compleción de la revisión bibliográfica y extracción de abstracts desde PubMed mediante su API (PEC2).
- **Hito 3 (Semana 11):** Implementación de modelos de Reconocimiento de Entidades Biomédicas (NER) y desarrollo de scripts de minería de datos para análisis de patrones (PEC3).
- **Hito 4 (Semana 15):** Desarrollo completo de la interfaz web en Streamlit, incluyendo el chatbot conversacional basado en BioGPT y funcionalidades de búsqueda semántica (PEC4).

- **Hito 5 (Semana 15):** Redacción y entrega de la memoria final del TFM, incluyendo la documentación del sistema y los resultados obtenidos (PEC4).

El cronograma detallado de estas fases y entregas puede consultarse en el Anexo 7, donde se presenta el Diagrama de Gantt correspondiente al desarrollo del proyecto.

1.5.3. Identificación y Mitigación de Riesgos

Además de la planificación temporal, se han considerado posibles riesgos que podrían afectar el desarrollo del proyecto. A continuación se listan los riesgos más relevantes, junto con las estrategias de mitigación propuestas:

- **Riesgo 1: Retrasos en la obtención de datos o acceso a la API de PubMed.** *Mitigación:* Preparar un conjunto de datos de prueba o almacenar localmente copias parciales de abstracts para poder avanzar en la implementación y el preprocesamiento aun cuando la API esté momentáneamente inaccesible.
- **Riesgo 2: Complejidad o incompatibilidad de librerías para modelos de PLN (BioBERT, PubMedBERT, BioMedBERT).** *Mitigación:* Revisar la documentación de cada modelo y realizar pruebas preliminares con un subconjunto de datos. Mantener librerías y entornos virtuales actualizados (por ejemplo, **conda** o **venv**). En caso de incompatibilidad, pivotar a un modelo similar o versión anterior confirmada como estable.
- **Riesgo 3: Bajo rendimiento del modelo o resultados poco fiables.** *Mitigación:* Ajustar hiperparámetros, probar diferentes enfoques de preprocesamiento y realizar experimentos con distintos modelos de lenguaje.
- **Riesgo 4: Problemas de escalabilidad en la interfaz web o en la integración del chatbot.** *Mitigación:* Desarrollar una primera versión *mínima viable* (MVP) del chatbot y escalar las funcionalidades gradualmente. Utilizar un servidor local robusto y, si fuese necesario, considerar servicios en la nube para pruebas de alta concurrencia.
- **Riesgo 5: Falta de tiempo para la documentación y redacción de la memoria.** *Mitigación:* Dedicar parte de cada sprint a la elaboración y actualización de la documentación. Llevar un *log* detallado de cambios y decisiones técnicas para que la redacción final sea más ágil.

Capítulo 2

Estado del Arte

2.1. Depresión mayor: impacto y tratamientos farmacológicos

En el ámbito de la salud mental, la depresión mayor ha sido ampliamente estudiada desde una perspectiva clínica y farmacológica. Diversas revisiones sistemáticas y metaanálisis han evaluado la eficacia de tratamientos como los inhibidores selectivos de la recaptación de serotonina (ISRS), los antidepresivos tricíclicos o los moduladores de neurotransmisores como la dopamina y la noradrenalina, demostrando efectos positivos en múltiples estudios, aunque con una respuesta clínica variable entre pacientes [5, 4].

Esta heterogeneidad ha motivado investigaciones centradas en la personalización del tratamiento antidepresivo. Entre las estrategias exploradas, destacan los enfoques basados en el análisis de grandes volúmenes de literatura científica, utilizando herramientas computacionales para identificar patrones y asociaciones relevantes. Estas técnicas permiten avanzar hacia una medicina más personalizada y basada en evidencia.

En este sentido, el uso de bases de datos biomédicas como PubMed, combinado con modelos de lenguaje entrenados en el dominio biomédico (como BioBERT o BioMedBERT), ha facilitado la exploración automática de información científica sobre la eficacia de distintos tratamientos en poblaciones diversas [9, 10]. Esta línea de trabajo ha abierto nuevas posibilidades para comprender mejor el rendimiento terapéutico en función de características clínicas específicas, aportando valor tanto en investigación como en apoyo a la decisión clínica.

2.2. Bases de datos biomédicas y PubMed

La investigación biomédica moderna depende en gran medida del acceso a bases de datos científicas que recopilan estudios clínicos, revisiones sistemáticas y metaanálisis. Entre ellas, *PubMed* es la base de datos de referencia a nivel internacional. Gestionada por el National Center for Biotechnology Information (NCBI), PubMed contiene más de 36 millones de registros bibliográficos relacionados con ciencias de la vida y la salud [6].

Su amplio volumen y crecimiento continuo la convierten en una fuente invaluable para investigadores clínicos y biomédicos [18]. Sin embargo, el tamaño de PubMed también presenta un reto: realizar una revisión exhaustiva de la literatura de forma manual resulta impracticable,

lo que abre la puerta al uso de herramientas automatizadas para el procesamiento y análisis de los textos [19].

2.3. Procesamiento de Lenguaje Natural en biomedicina

El *Procesamiento de Lenguaje Natural* (PLN) ha ganado un papel protagonista en el análisis de textos biomédicos [20, 21]. Gracias a técnicas como la tokenización, la extracción de entidades, la resolución de referencias o la clasificación semántica, es posible transformar grandes volúmenes de información no estructurada en datos analizables.

En biomedicina, el PLN se utiliza para tareas como la extracción de relaciones entre genes y enfermedades, la detección de efectos adversos de medicamentos o el mapeo automático de conceptos clínicos [7, 22]. Sin embargo, los textos biomédicos presentan particularidades —como el uso de terminología técnica y abreviaturas— que complican el uso de herramientas de PLN generalistas, haciendo necesario el uso de modelos específicos entrenados en corpus biomédicos [9, 10].

2.4. Modelos biomédicos preentrenados (BioBERT, PubMedBERT, BioMedBERT)

El desarrollo de modelos de lenguaje preentrenados específicos para el dominio biomédico ha impulsado notablemente el procesamiento automático de literatura científica. Entre los más representativos se encuentran:

- **BioBERT** [9], una adaptación de BERT entrenada adicionalmente sobre corpora biomédicos como PubMed y PMC, que mejora el rendimiento en tareas de NER y QA biomédicas.
- **PubMedBERT** [10], entrenado desde cero exclusivamente sobre textos de PubMed, lo que le permite superar a BioBERT en tareas de comprensión semántica más profunda.
- **BioMedBERT**, variante que extiende PubMedBERT incluyendo notas clínicas y otros textos médicos, mejorando el desempeño en entornos clínicos reales.

Estos modelos han demostrado superar en rendimiento a modelos generalistas en tareas biomédicas específicas, confirmando la importancia de adaptar el preentrenamiento al dominio del problema.

2.5. Aplicaciones existentes de minería de textos biomédicos

Diversas herramientas han sido desarrolladas en los últimos años para aplicar técnicas de procesamiento del lenguaje natural (PLN) a la exploración de literatura biomédica. Estas aplicaciones suelen centrarse en áreas específicas o tareas concretas, como la medicina personalizada, la investigación genómica o la literatura sobre COVID-19. Algunos ejemplos destacados incluyen:

- **Text Mining for Precision Medicine** [23], que analiza textos científicos para descubrir asociaciones entre biomarcadores y terapias personalizadas.
- **Deep Semantic Mining** [24], que utiliza embeddings semánticos para mapear relaciones entre conceptos biomédicos y acelerar la generación de hipótesis clínicas.
- **LitCovid** [25], una iniciativa del NCBI para clasificar automáticamente la literatura sobre COVID-19, demostrando la aplicabilidad del PLN a problemas de revisión rápida de literatura científica.

Aunque estas herramientas representan avances importantes, en general se enfocan en dominios muy concretos y no están diseñadas para analizar de forma integral tratamientos farmacológicos en áreas como la depresión mayor. En este contexto, se hace necesario desarrollar plataformas más específicas, flexibles y orientadas a la investigación clínica.

2.6. Justificación del presente trabajo

El presente trabajo busca cubrir este vacío mediante el desarrollo de una herramienta que, combinando técnicas de Procesamiento de Lenguaje Natural, minería de datos y Recuperación Aumentada con Generación (RAG) [12], facilite el análisis automatizado de la eficacia de tratamientos farmacológicos para la depresión mayor.

La integración de tecnologías como BioMedBERT[10] y sistemas de recuperación semántica no solo optimiza el acceso a la información relevante, sino que también ofrece una interfaz accesible para investigadores clínicos y profesionales de la salud, promoviendo una toma de decisiones más informada y basada en evidencia.

Capítulo 3

Materiales y métodos

3.1. Diseño general del trabajo

El presente trabajo se ha planteado como un desarrollo aplicado en el ámbito de la bioinformática y la inteligencia artificial, con el objetivo de construir una herramienta interactiva para el análisis de la eficacia de tratamientos farmacológicos para la depresión mayor a partir de *abstracts* científicos. Para ello, se ha seguido un enfoque basado en minería de datos y modelos de lenguaje entrenados en el dominio biomédico, integrados en una aplicación web de consulta y visualización.

El diseño modular del proyecto ha permitido dividir el desarrollo en varios componentes independientes y fácilmente escalables, organizados en directorios temáticos según su función específica dentro del flujo de trabajo.

3.2. Estructura del proyecto y materiales empleados

El proyecto se ha estructurado de la siguiente manera:

- `api/`: scripts para la extracción de *abstracts* desde la API de PubMed [6].
- `preprocessing/`: limpieza, normalización y preparación de los textos.
- `ner/`: módulo de reconocimiento de entidades biomédicas mediante modelos como Bio-MedBERT [10].
- `embedding/`: generación de vectores semánticos para búsqueda semántica usando FAISS [17].
- `mining/`: análisis de co-ocurrencias, tendencias y frecuencias.
- `web_app/`: aplicación web con visualización y chatbot conversacional.
- `config/`: configuración general del proyecto.
- `query/`: funciones de recuperación de información.

- `output/`: almacenamiento de resultados.
- `README.md`, `requirements.txt`: documentación y dependencias.

Las tecnologías utilizadas incluyen Python 3 y librerías como `transformers`, `spacy`, `pandas`, `nltk`, `scikit-learn`, `FAISS`[17] y `Streamlit`. Para el procesamiento del lenguaje natural biomédico se han empleado modelos especializados como BioBERT [9], PubMedBERT [10], Bio_ClinicalBERT y BioGPT [26, 16]. El desarrollo web se ha realizado con un framework ligero como Streamlit. El control de versiones se ha gestionado con Git y GitHub.

3.3. Metodología seguida

El desarrollo del trabajo se ha dividido en las siguientes fases metodológicas:

1. **Revisión bibliográfica:** Se recopilaron antecedentes sobre aplicaciones de Procesamiento del Lenguaje Natural (PLN) en biomedicina, incluyendo modelos preentrenados y soluciones similares orientadas al análisis de literatura científica.
2. **Extracción de datos:** Se obtuvieron abstracts científicos desde PubMed utilizando su API oficial [6], a partir de términos libres y descriptores *MeSH* (Medical Subject Headings), un vocabulario controlado utilizado por PubMed para indexar y organizar artículos científicos. Estos términos permiten mejorar la precisión y exhaustividad en la recuperación de información relacionada con la depresión mayor y los tratamientos farmacológicos.
3. **Preprocesamiento de textos:** Se aplicaron técnicas de limpieza, normalización y tokenización para preparar los textos. También se eliminaron duplicados y se adaptaron los textos largos para ajustarse a los límites de entrada de los modelos.
4. **Reconocimiento de Entidades Biomédicas (NER):** Se utilizó un modelo BioMedBERT[10] adaptado para extraer entidades relevantes como fármacos, enfermedades o genes. El modelo fue ajustado mediante *transfer learning* usando un conjunto etiquetado de abstracts biomédicos.
5. **Generación de embeddings semánticos y búsqueda vectorial:** Se representaron los textos como vectores numéricos de alta dimensión utilizando BioMedBERT[10]. Estos *embeddings semánticos* capturan el significado contextual de cada abstract. Posteriormente, se implementó una búsqueda vectorial con FAISS [17], que permite comparar estos vectores y recuperar los abstracts más relevantes en función de su similitud semántica.
6. **Minería de datos y análisis exploratorio:** Se aplicaron métricas como TF-IDF [27], análisis de co-ocurrencias entre entidades y visualización de tendencias temporales para identificar patrones en la eficacia de los tratamientos.
7. **Desarrollo de la aplicación web:** Se creó una aplicación interactiva en Streamlit que permite consultar resultados, visualizar entidades reconocidas y explorar los datos procesados. La interfaz incluye también un chatbot conversacional basado en el enfoque de Recuperación Aumentada con Generación (RAG)[12], implementado con LangChain [13] y modelos de lenguaje biomédico como BioGPT [16] y Bio_ClinicalBERT [26].

8. **Evaluación y validación:** Se realizaron pruebas técnicas y funcionales para comprobar el correcto funcionamiento del sistema.

3.4. Decisiones clave y criterios adoptados

Durante el desarrollo se valoraron distintas alternativas metodológicas y tecnológicas:

- Se descartó el análisis manual por ser inviable ante el volumen de publicaciones.
- Se priorizó el uso de modelos biomédicos preentrenados frente a generalistas, dada su mayor precisión en el dominio específico.
- Se eligió BioMedBERT[10] por su equilibrio entre rendimiento, estabilidad y soporte.
- Se optó por frameworks ligeros (Streamlit) para la interfaz web, priorizando usabilidad y rapidez de despliegue.
- Se utilizó almacenamiento local durante el desarrollo para simplificar la ejecución y evitar costes.

Los criterios clave en la toma de decisiones fueron: precisión, escalabilidad, reproducibilidad, simplicidad y alineación con los objetivos del TFM.

3.5. Productos obtenidos

Los productos generados durante el desarrollo son:

- Aplicación web interactiva con paneles de búsqueda, visualización y navegación por entidades.
- Chatbot conversacional capaz de responder preguntas sobre tratamientos para la depresión mayor.
- Modelos BioMedBERT **ajustados** para tareas de reconocimiento de entidades biomédicas [10].
- Embeddings vectoriales de miles de *abstracts* biomédicos.
- Módulos de minería de datos para análisis de co-ocurrencias, tendencias y patrones.
- Scripts automatizados para la extracción, limpieza y análisis de literatura científica.
- Documentación técnica completa con instrucciones de uso y código reproducible.

3.6. Infraestructura y entorno de desarrollo

El desarrollo del proyecto se ha realizado en un equipo portátil con las siguientes características:

- CPU: Intel Core i7-1165G7 a 2.80GHz
- RAM: 16 GB DDR4
- Sistema operativo: Ubuntu 22.04 LTS
- Lenguaje principal: Python 3.10

La aplicación se ejecuta localmente mediante Streamlit, y puede desplegarse públicamente en plataformas como **Streamlit Cloud**, facilitando su acceso desde cualquier navegador sin necesidad de instalación local.

Capítulo 4

Resultados


Como resultado del trabajo realizado, se ha desarrollado una aplicación interactiva que permite explorar de forma accesible y visual la eficacia de tratamientos farmacológicos para la depresión mayor a partir de literatura científica indexada en PubMed [6]. Esta herramienta ha sido implementada utilizando **Streamlit** [14], una tecnología orientada a la creación rápida de aplicaciones web para ciencia de datos, con el objetivo de facilitar su uso a investigadores clínicos y profesionales de la salud sin conocimientos técnicos avanzados.

El análisis automático de grandes volúmenes de literatura biomédica mediante técnicas de minería de texto y procesamiento del lenguaje natural (PLN) se ha consolidado como una estrategia efectiva para la medicina de precisión y la investigación clínica [8, 23, 7, 24].

Para ilustrar el funcionamiento de la aplicación y mostrar el valor de los análisis que ofrece, se ha centrado el capítulo en dos fármacos ampliamente utilizados en la práctica clínica: **sertralina** y **fluoxetina** [5, 4]. Ambos pertenecen a la clase de inhibidores selectivos de la recaptación de serotonina (ISRS) y son habitualmente prescritos para el tratamiento de la depresión mayor.

4.1. Extracción y almacenamiento de datos

La primera etapa del proceso consistió en la definición y ejecución de una búsqueda estructurada en PubMed. Para ello, se elaboró una query compleja que combinaba descriptores MeSH y términos libres con el fin de recuperar ensayos clínicos relacionados con tratamientos farmacológicos para la depresión mayor. La consulta se muestra a continuación:



```

1  (
2    "Major Depressive Disorder"[MeSH]
3    OR "major depression"[tiab]
4    OR "unipolar depression"[tiab]
5    OR "mdd"[tiab]
6  )
7  AND (pharmacological treatment OR drug therapy OR antidepressants)
8  AND (clinical trial[ptyp] OR randomized controlled trial[ptyp])
9  AND 1990:2025[dp]
10 |

```

Figura 4.1: Query utilizada para recuperar ensayos clínicos sobre tratamientos para la depresión en PubMed.

Tras ejecutar la búsqueda mediante la API de Entrez, se descargaron un total de **3869 abstracts únicos**, almacenados en una base de datos local MongoDB para facilitar su posterior procesamiento y análisis.

Cada documento de la base de datos contiene los siguientes campos clave:

- **pmid:** Identificador único de PubMed.
- **title y abstract:** Información textual principal del estudio.
- **date:** Fecha de publicación, usada en análisis temporales.
- **entities:** Lista de entidades reconocidas mediante modelos de NER biomédico, incluyendo el tipo (fármaco, enfermedad, gen, etc.), puntuaciones de confianza y localización dentro del texto.
- **processed:** Listas de tokens relevantes extraídos para tareas de minería de texto.
- **summary:** Resumen automático generado para facilitar una vista rápida del contenido.

La elección de MongoDB como sistema de almacenamiento permite manejar documentos JSON complejos y anidados, lo que resulta ideal para representar de forma flexible tanto el contenido original del artículo como las anotaciones generadas por los distintos módulos del sistema. Esta estructura soporta consultas específicas sobre términos, fechas o entidades, y actúa como fuente común para los siguientes componentes del sistema: visualización de entidades, búsqueda semántica, minería de co-ocurrencias y generación de respuestas mediante el asistente conversacional.

A modo de ejemplo, uno de los documentos extraídos corresponde al artículo con PMID 15927091, en el que se identificaron entidades como *acute phase proteins*, *albumin*, *cortisol*, *CRP*, *panic disorder*, y *major depression*, junto con un resumen automático que destaca la relación entre respuesta inflamatoria y eficacia del tratamiento con ISRS.

El contenido íntegro de este documento, incluyendo campos clave y entidades reconocidas, puede consultarse en el Anexo 7, donde se presenta una muestra representativa de la base de datos MongoDB resultante.

4.2. Procesamiento de entidades biomédicas

Una vez recopilados los textos, se aplicaron modelos de reconocimiento de entidades nombradas (NER) específicos del dominio biomédico [9, 10]. En concreto, se utilizaron los modelos `judithrosell/JNLPBA_PubMedBERT_NER`, `judithrosell/BC5CDR_PubMedBERT_NER` y `judithrosell/BioNLP13CG_PubMedBERT_NER`, configurados dentro del pipeline de procesamiento. Para garantizar la fiabilidad de las entidades extraídas, se estableció un umbral mínimo de confianza de 0.61. Además, se limitó el número máximo de tokens a procesar por documento a 512, con el fin de respetar las restricciones de los modelos utilizados.

En total, se identificaron entidades en **3853 abstracts**. Para ambos casos de estudio, sertralina y fluoxetina, se extrajeron múltiples menciones de tipo **Chemical**, **Outcome** y **Disease**, lo que permitió continuar con los análisis posteriores.

4.3. Análisis agregado de la literatura

Para facilitar el estudio comparado de los tratamientos farmacológicos en depresión mayor, se ha desarrollado un panel de análisis agregado que permite visualizar, explorar e interpretar la literatura recopilada de forma interactiva. Esta funcionalidad se integra en la aplicación desarrollada en Streamlit [14] y ofrece distintos modos de exploración agregada.

Fármacos más mencionados

Una primera vista general se ofrece mediante un gráfico de barras que muestra los veinte medicamentos más mencionados en los abstracts analizados. Este análisis se basa en la extracción automática de entidades del tipo **Chemical**. En este ranking destacan fármacos ampliamente conocidos como **fluoxetina** y **sertralina**, ambos inhibidores selectivos de la recaptación de serotonina (ISRS) con demostrada eficacia en trastornos depresivos [5, 4].



Figura 4.2: Principales fármacos mencionados en la literatura analizada.

Co-ocurrencias fármaco–resultado clínico

Uno de los análisis más reveladores es el estudio de co-ocurrencias entre medicamentos y términos asociados a eficacia clínica. Se han identificado asociaciones frecuentes con términos como *remission*, *response*, *relapse* e *improvement*, los cuales permiten inferir que estos fármacos forman parte de ensayos clínicos que reportan resultados positivos o negativos [23, 8].

En este contexto, se considera “resultado positivo” toda co-ocurrencia en la que un fármaco aparece mencionado junto a términos relacionados con mejoría clínica, como *remission*, *response* o *improvement*, lo cual sugiere un efecto beneficioso reportado en el abstract analizado.

En la tabla siguiente se muestran algunas de las co-ocurrencias más destacadas. Como puede observarse, sertralina y fluoxetina presentan numerosas apariciones junto a términos de resultado positivo, lo que refuerza su rol central en la literatura clínica.




Figura 4.3: Ejemplos de co-ocurrencias entre fármacos y resultados clínicos.

Este análisis se complementa con un mapa de calor (*heatmap*) que visualiza la intensidad de dichas relaciones, donde el color representa la frecuencia de coaparición.




Figura 4.4: Mapa de calor de co-ocurrencias entre tratamientos y resultados clínicos.

Evolución temporal de menciones

El análisis temporal ofrece una perspectiva longitudinal sobre la presencia de distintos tratamientos farmacológicos en la literatura. Se ha generado una gráfica que muestra el número de menciones por año para todas las entidades reconocidas como **Chemical** desde 1990 hasta la actualidad.




Figura 4.5: Número de menciones anuales de tratamientos farmacológicos en los abstracts.

Además, se ha incorporado una herramienta de selección múltiple que permite al usuario explorar la evolución específica de uno o más fármacos. La Figura siguiente muestra la comparación entre **fluoxetina** y **sertralina**, revelando diferencias en su evolución y popularidad relativa.




Figura 4.6: Comparativa temporal entre sertralina y fluoxetina.

Grafo de relaciones semánticas

Como herramienta complementaria se ha construido un grafo de relaciones entre medicamentos y resultados clínicos, modelando las co-ocurrencias como una red. Cada nodo representa una entidad (fármaco o resultado), y cada arista indica una coaparición en un abstract. La intensidad de las relaciones se refleja mediante el grosor de las aristas y el tamaño del nodo, permitiendo detectar de forma visual los elementos más centrales [24, 7].




Figura 4.7: Red semántica de tratamientos y resultados clínicos.

Además, se permite aplicar filtros específicos para analizar en detalle la red asociada a un fármaco concreto. A continuación, se muestran los subgrafos obtenidos al aislar las conexiones de sertralina y fluoxetina, respectivamente:




Figura 4.8: Subgrafos de relaciones de sertralina (izquierda) y fluoxetina (derecha).

Este análisis agregado permite no solo obtener una visión general del conjunto de datos, sino también detectar patrones y tendencias relevantes para la investigación clínica. El uso combinado de procesamiento de lenguaje natural, minería de texto y visualización interactiva facilita una exploración profunda de la literatura biomédica más allá de los enfoques tradicionales.

4.4. Exploración semántica de literatura

Una de las funcionalidades más potentes integradas en la aplicación es la búsqueda semántica de abstracts. Esta permite a los investigadores realizar consultas en lenguaje natural en inglés y obtener como resultado aquellos artículos más cercanos en significado, independientemente de que coincidan literalmente los términos. Para ello, se ha implementado una arquitectura basada en **embeddings biomédicos** y recuperación por similitud vectorial.

Los textos han sido representados como vectores de alta dimensión mediante modelos pre-entrenados del tipo **all-MiniLM-L6-v2**, optimizados para tareas de búsqueda semántica. La indexación y recuperación se ha realizado con la biblioteca **FAISS** (Facebook AI Similarity Search) [17], que permite realizar búsquedas eficientes incluso sobre decenas de miles de vectores. Esta estrategia ha demostrado su utilidad en minería semántica del texto biomédico [24].

Para demostrar su funcionamiento, se introdujo en la interfaz la siguiente consulta:

efficacy of sertraline in elderly patients

Al lanzar la búsqueda, el sistema devuelve una lista ordenada de los abstracts más relevantes, asignando a cada uno un nivel de relevancia basado en la distancia vectorial con respecto a la consulta original. En la Figura 4.9 se muestran los resultados obtenidos, donde pueden observarse artículos con diferentes grados de coincidencia semántica.




Figura 4.9: Resultado de búsqueda semántica sobre la eficacia de la sertralina en pacientes de edad avanzada.

Además del listado de resultados relevantes, la aplicación permite expandir cada uno de ellos para acceder a información enriquecida. Esta ficha detallada incluye:

- **Distancia FAISS:** una métrica de similitud numérica entre la consulta del usuario y el texto recuperado.
- **Resumen automático:** generado mediante algoritmos de extracción textual, permite captar la idea central del abstract en una única lectura rápida.
- **Entidades biomédicas reconocidas:** resaltadas dentro del texto completo del abstract. Se etiquetan automáticamente conceptos como medicamentos, enfermedades, síntomas y resultados clínicos, utilizando modelos especializados en NER biomédico [9, 10].
- **Acceso directo al artículo original:** mediante un enlace activo a la fuente en PubMed [6].

En la Figura 4.10 se presenta una ficha de un artículo altamente relevante para la consulta sobre la eficacia de la sertralina en pacientes de edad avanzada. En el texto se observan múltiples menciones a este fármaco, así como la aparición de términos clínicamente significativos como *depression*, *anxiety*, *remission* o *suicidal ideation*, los cuales han sido etiquetados automáticamente mediante el sistema de reconocimiento de entidades como entidades del tipo **Disease** o **Chemical**, entre otros. Esta visualización permite identificar rápidamente conceptos clave en el contexto biomédico del abstract.




Figura 4.10: Ficha detallada del artículo seleccionado por similitud semántica. Incluye resumen automático, entidades NER y acceso a PubMed.

Esta funcionalidad permite superar las limitaciones de las búsquedas literales y localizar literatura relevante incluso cuando los términos empleados en los estudios no coinciden exactamente con los utilizados en la consulta del usuario. Para investigadores clínicos, esta capacidad resulta especialmente útil en etapas de revisión sistemática, identificación de evidencia o selección de estudios relacionados.

Asimismo, esta arquitectura semántica constituye la base del asistente conversacional integrado en la aplicación, ya que permite localizar los abstracts más relevantes antes de generar una respuesta en lenguaje natural mediante modelos generativos, siguiendo el paradigma de **Recuperación Aumentada por Generación (RAG)** [12].

4.5. Caso clínico interactivo

Una de las funcionalidades más relevantes de la herramienta es el módulo de **caso clínico interactivo**, diseñado para facilitar la consulta dirigida de literatura científica a partir del nombre de un fármaco específico. Esta utilidad permite a investigadores y profesionales sanitarios explorar rápidamente cuál es la presencia y el contexto clínico en que se menciona un determinado tratamiento en los abstracts extraídos de PubMed [6].

A través de una interfaz sencilla e intuitiva, el usuario puede introducir un fármaco y obtener un resumen cuantitativo de su presencia en la base de datos, además de una recopilación de ejemplos relevantes donde se identifican menciones explícitas a resultados clínicos como *response*, *remission*, *recovery* o *relapse*. Esta información resulta particularmente útil para apoyar revisiones sistemáticas, generar hipótesis clínicas o contrastar decisiones terapéuticas.

En el caso de la **sertralina**, se identificaron **299 documentos** con su mención. De ellos, **286 abstracts** contenían además términos relacionados con eficacia clínica. La herramienta muestra ejemplos representativos, junto con un acceso directo al artículo completo en PubMed.



Caso de Uso Clínico: Exploración de un farmaco

Introduce el nombre del farmaco (minúsculas):
sertraline

Documentos devueltos por el filtro: 299

De ellos, 286 abstracts mencionan términos de eficacia clínica.

Ejemplos de contexto clínico:

Three 6-8 week comparative studies have shown sertraline to be an effective, safe and well-tolerated treatment for acute depressive illness. The first, a double-blind fixed-dose study, demonstrated the efficacy of sertraline over placebo; the second, a forced upward titration, active- and placebo-co...

[Ver en PubMed](#)

BACKGROUND: Antidepressant medication (ADM) is thought to reduce depressive symptoms by altering emotion-generative brain systems. However, it is unknown whether successful ADM treatment is associated with changes in psychobehavioral strategies used to regulate emotions. We examined depressive sympt...

[Ver en PubMed](#)

The efficacy and tolerability of sertraline in 422 out-patients with major depression (DSM-III-R) was evaluated in an open multicentre 8-month study. Patients received sertraline 50 mg/day; if there was insufficient response at week 4, the dose was increased to 100 mg/day. After 8 weeks, 68.6% of pa...

[Ver en PubMed](#)

BACKGROUND: Depression occurs frequently in patients with acute myocardial infarction and is associated with increased mortality rates. It is not known whether serotonin reuptake inhibitors would be safe and effective for patients with depression after myocardial infarction and whether such treatmen...

[Ver en PubMed](#)

Figura 4.11: Resumen estadístico y ejemplos clínicos sobre sertralina.

Del mismo modo, la consulta para **fluoxetina** arrojó un total de **424 documentos**, entre los cuales **405 abstracts** hacían referencia a resultados clínicos directamente relacionados.



Caso de Uso Clínico: Exploración de un farmaco

Introduce el nombre del farmaco (minúsculas):
fluoxetine

Documentos devueltos por el filtro: 424

De ellos, 405 abstracts mencionan términos de eficacia clínica.

Ejemplos de contexto clínico:

We examined whether fluoxetine treatment has persistent effects on electroencephalographic sleep after drug discontinuation in patients with recurrent major depression. Age-matched groups of 23 women were treated with interpersonal psychotherapy alone (IPT) or fluoxetine plus interpersonal psychothe...

[Ver en PubMed](#)

The authors investigated whether there were differences in caudate and lenticular nucleus volumes in depressed patients relative to comparison subjects, and whether differences in basal ganglia volume were associated with treatment response to fluoxetine. Brain magnetic resonance images were obtaine...

[Ver en PubMed](#)

BACKGROUND: Pindolol has been reported to hasten the antidepressant action of selective serotonin reuptake inhibitors in open-label and placebo-controlled trials. Pilot studies also suggested that pindolol could augment the antidepressant response in unresponsive patients. We investigated whether th...

[Ver en PubMed](#)

OBJECTIVE: We previously reported that morning bright light therapy is efficacious in adults with nonseasonal major depressive disorder (MDD), both on its own and in combination with fluoxetine. Given that appetitive symptoms predict response to bright light therapy in seasonal depression, we examin...

[Ver en PubMed](#)

Figura 4.12: Resumen estadístico y ejemplos clínicos sobre fluoxetina.

Esta sección representa un ejemplo claro de cómo el diseño centrado en el usuario puede facilitar el acceso y la interpretación de grandes volúmenes de literatura científica, reduciendo significativamente el esfuerzo requerido para filtrar, agrupar y contextualizar la información biomédica más relevante.

4.6. Asistente clínico con inteligencia artificial

Como funcionalidad adicional, se ha desarrollado un **asistente clínico conversacional**, diseñado para responder preguntas médicas formuladas en lenguaje natural en inglés. Este módulo representa un ejemplo práctico de integración entre recuperación semántica de información biomédica y modelos de lenguaje, siguiendo el enfoque de *Recuperación Aumentada por Generación* (RAG) [12].

La arquitectura se basa en un sistema híbrido:

- En primer lugar, se aplica un modelo **Bio_ClinicalBERT** [9], especializado en lenguaje clínico, que intenta extraer directamente desde los abstracts el fragmento de texto más relevante como respuesta (QA extractiva).
- Si la respuesta recuperada no es **suficientemente informativa** —es decir, si el texto extraído no aporta detalles relevantes, concretos o clínicamente útiles para la pregunta formulada—, se activa un sistema de **generación libre** con el modelo BioGPT-Large, que construye una respuesta textual completa a partir del contexto recuperado.

El usuario introduce su pregunta, y el sistema recupera mediante FAISS [17] los abstracts más relevantes. A continuación, se genera una respuesta basada en la evidencia disponible, utilizando la mejor estrategia según el tipo de pregunta.

Por ejemplo, ante la consulta:

What are the clinical outcomes of sertraline in adults with major depression?

El asistente generó las siguientes respuestas:

- **Respuesta de Bio_ClinicalBERT:** *to be consistently superior to placebo and equivalent in therapeutic effect to amitriptyline.*
- **Respuesta de BioGPT:** *...sertraline is an effective, safe and well-tolerated treatment for major depression in older adults...*




Figura 4.13: Ejemplo de respuesta generada sobre los efectos clínicos de la sertralina.

Otro ejemplo de pregunta más específica fue:

What is the rate of remission for fluoxetine in major depressive disorder?

En este caso, ambos modelos ofrecieron fragmentos relevantes extraídos de ensayos clínicos:




Figura 4.14: Ejemplo de respuesta generada sobre la tasa de remisión de fluoxetina.

Finalmente, ante una consulta relacionada con efectos adversos:

What side effects are associated with sertraline treatment?

El sistema devolvió una descripción coherente y clínica:




Figura 4.15: Respuesta del asistente clínico sobre los efectos adversos de la sertralina.

Cabe destacar que este módulo se encuentra en estado **beta** y que, para alcanzar un nivel de precisión adecuado para entornos clínicos reales, sería necesario continuar su entrenamiento, disponer de infraestructura más robusta, e integrar filtros adicionales que validen la calidad y veracidad de las respuestas generadas. Aun así, los resultados obtenidos demuestran que el asistente es capaz de identificar respuestas coherentes y contextualmente relevantes, y que puede ser de utilidad como herramienta de apoyo exploratorio en contextos de investigación biomédica.

Además, los abstracts utilizados como evidencia se muestran también al usuario, permitiendo una verificación directa de la fuente de información, lo que aporta transparencia y capacidad de validación a cada respuesta generada.

4.6.1. Comparación con herramientas similares

Además de las aplicaciones generales, existen plataformas más directamente comparables con el sistema desarrollado, enfocadas en el análisis de textos biomédicos de PubMed. Entre las más relevantes se encuentran:

- **LitSense**, desarrollada por el NCBI [28], que ofrece búsqueda semántica avanzada sobre PubMed mediante modelos de lenguaje. Si bien mejora la relevancia de los resultados, no incorpora visualización de entidades ni asistentes conversacionales.

- **iPubMed Explorer** [29], centrada en la navegación interactiva de relaciones entre conceptos biomédicos. Aunque ofrece visualizaciones útiles, no integra recuperación semántica contextual ni generación de lenguaje natural.
- **PubTator Central** [30], ampliamente utilizada para la anotación automática de entidades. Está enfocada en NER, pero carece de interfaz conversacional o mecanismos de síntesis generativa.

En contraste, el sistema propuesto en este Trabajo de Fin de Máster combina múltiples capacidades en una sola aplicación web:

- Reconocimiento de entidades biomédicas con modelos especializados.
- Búsqueda semántica mediante embeddings y recuperación vectorial.
- Visualización interactiva de co-ocurrencias y análisis exploratorio.
- Asistente conversacional basado en recuperación aumentada con generación (RAG) [12].

Esta integración convierte la herramienta en una solución completa, flexible y centrada en el usuario, diseñada para asistir tanto a investigadores como a profesionales clínicos en la exploración de tratamientos farmacológicos para la depresión mayor.

Capítulo 5

Conclusiones y trabajos futuros

5.1. Conclusiones

Este Trabajo de Fin de Máster ha demostrado la viabilidad de diseñar e implementar una herramienta completa para el análisis automatizado de literatura biomédica en el contexto de la depresión mayor. El sistema combina la recuperación semántica de información, el reconocimiento de entidades clínicas, análisis exploratorio visual y un módulo conversacional basado en inteligencia artificial.

Conclusiones extraídas del trabajo

Los resultados han sido, en líneas generales, satisfactorios y acordes a las expectativas iniciales. Se ha logrado extraer información coherente a partir de miles de abstracts y presentarla de forma útil para su análisis clínico. Ha sido especialmente destacable comprobar que, con los modelos adecuados, es posible responder a preguntas médicas reales con evidencia científica contenida en la literatura publicada.

Logro de los objetivos iniciales

Se han alcanzado todos los objetivos planteados al inicio del proyecto:

- Descarga y preprocesamiento automatizado de abstracts desde PubMed.
- Reconocimiento de entidades biomédicas (fármacos, enfermedades, resultados clínicos).
- Análisis agregado de frecuencia, evolución temporal y co-ocurrencias.
- Exploración semántica basada en embeddings.
- Implementación de un chatbot clínico con arquitectura RAG.

Todos los módulos han sido funcionales, integrados en una aplicación interactiva, y probados mediante casos reales centrados en sertralina y fluoxetina.

Impacto ético-social, sostenibilidad y diversidad

Desde un punto de vista ético y social, la herramienta contribuye positivamente a la democratización del acceso al conocimiento científico. Aunque no sustituye al juicio clínico, puede facilitar la toma de decisiones basada en evidencia. No se han detectado impactos negativos relacionados con la privacidad, el sesgo algorítmico o la discriminación, ya que el sistema opera únicamente sobre datos públicos y no maneja información personal.

En términos de sostenibilidad, el uso de modelos preentrenados y de código abierto ha permitido desarrollar la solución con una huella computacional moderada. El despliegue local o en la nube puede ajustarse fácilmente al entorno disponible. Además, la arquitectura modular y el uso de software libre garantizan su reutilización y mantenimiento.

Lecciones aprendidas

El trabajo ha permitido adquirir competencias prácticas en el manejo de grandes volúmenes de texto biomédico, así como en la integración de modelos de lenguaje y técnicas de visualización. También ha quedado patente la importancia de una validación crítica de los resultados generados automáticamente, especialmente en contextos clínicos.

5.2. Seguimiento de la planificación

Evaluación de la planificación y metodología

La planificación inicial ha sido seguida en gran medida, aunque con ligeros ajustes en los tiempos debido a la complejidad de algunos módulos, como el asistente conversacional.

La metodología prevista, basada en procesamiento secuencial de texto con módulos independientes, ha sido adecuada. Sin embargo, fue necesario introducir dos modificaciones clave:

- Uso de un sistema híbrido de respuesta para el chatbot, combinando extracción y generación.
- Implementación de scripts y pruebas locales para permitir el uso del sistema sin necesidad de conexión a una base de datos remota.

Ambos cambios han permitido mantener el objetivo técnico sin comprometer la funcionalidad.

5.3. Líneas de trabajo futuro

El proyecto deja abiertas múltiples posibilidades de mejora y consolidación:

- Integrar textos completos de artículos, no solo los abstracts, para una extracción de información más profunda y precisa.

- Ampliar las capacidades de reconocimiento de entidades mediante modelos más sofisticados o versiones afinadas de BioBERT, incluyendo nuevas categorías como tratamientos combinados o biomarcadores.
- Aplicar técnicas de evaluación automática de calidad metodológica de los estudios (análisis de p-valores, tamaños muestrales, diseño experimental), para ponderar la evidencia recogida.
- **Realizar una validación clínica colaborativa**, en la que expertos del ámbito médico participen en la evaluación de tres componentes clave del sistema:
 - La *precisión del reconocimiento de entidades* biomédicas (NER).
 - La *pertinencia y relevancia clínica de los resultados* de búsqueda semántica.
 - La *calidad y utilidad de las respuestas generadas por el asistente conversacional*, en el contexto de la toma de decisiones clínicas.
- Extender el dominio temático del sistema a otras patologías de interés clínico, como oncología, enfermedades infecciosas o trastornos neurológicos.
- Incorporar la posibilidad de que los investigadores carguen sus propios corpus personalizados, para analizar conjuntos específicos de estudios según sus intereses.

Estas líneas de trabajo permitirán evolucionar el sistema hacia una herramienta más robusta, validada y adaptada a las necesidades reales de los entornos clínicos y de investigación biomédica.

Capítulo 6

Glosario

Abstract: Resumen estructurado de un artículo científico. En este trabajo se han utilizado los abstracts disponibles públicamente en PubMed como fuente principal de información.

Análisis de co-ocurrencias: Técnica de minería de texto que identifica la frecuencia con la que dos conceptos aparecen conjuntamente en un mismo documento. En este proyecto se ha aplicado para estudiar relaciones entre fármacos y resultados clínicos.

Análisis semántico: Técnica que permite comparar significados entre textos. Utilizada aquí para buscar estudios relevantes a partir de consultas en lenguaje natural mediante embeddings y FAISS [17].

BioGPT: Modelo de lenguaje generativo especializado en textos biomédicos. En este proyecto se ha utilizado como generador de respuestas cuando no se encuentra una respuesta clara mediante extracción directa.

Bio_ClinicalBERT: Modelo de lenguaje basado en BERT, entrenado con historias clínicas y notas médicas. Utilizado para tareas de extracción de respuesta mediante pregunta-respuesta (QA extractiva).

Chatbot clínico: Módulo conversacional del sistema que permite formular preguntas médicas en lenguaje natural y recibir respuestas generadas a partir de los abstracts más relevantes.

Clustering: Técnica de agrupamiento utilizada en minería de texto para agrupar documentos similares entre sí según sus representaciones TF-IDF[27].

Consulta semántica: Pregunta formulada en lenguaje natural que se transforma en vector de búsqueda para encontrar los textos más similares a nivel de significado.

Co-ocurrencia: Presencia conjunta de dos entidades (por ejemplo, un fármaco y un outcome clínico) en el mismo abstract.

Embeddings: Representaciones vectoriales densas de palabras, frases o documentos que capturan su significado semántico. Utilizadas para comparar textos mediante distancias vectoriales.

Entidades biomédicas: Términos clínicos como nombres de fármacos, enfermedades o síntomas extraídos de los abstracts mediante modelos NER.

FAISS (Facebook AI Similarity Search): Biblioteca desarrollada por Facebook AI Research para realizar búsquedas por similitud en grandes volúmenes de vectores. Es fundamental para el módulo de búsqueda semántica del sistema..

Fluoxetina: Antidepresivo de la clase de ISRS (inhibidores selectivos de la recaptación de serotonina), utilizado como uno de los casos clínicos de análisis en el TFM.

Interfaz interactiva: Aplicación web desarrollada en Streamlit que permite visualizar, buscar y explorar los resultados de forma gráfica e intuitiva.

ISRS: Inhibidores Selectivos de la Recaptación de Serotonina. Clase de fármacos utilizada en el tratamiento de la depresión, donde destacan la sertralina y la fluoxetina.

MongoDB: Base de datos NoSQL utilizada para almacenar los abstracts descargados y las entidades extraídas de manera flexible y escalable.

NER (Named Entity Recognition): Técnica de procesamiento del lenguaje natural que identifica y clasifica entidades en texto. En este TFM se aplica para detectar nombres de medicamentos, enfermedades y resultados.

Outcome clínico: Resultado observado o medido en un paciente como consecuencia de un tratamiento, por ejemplo *remission*, *response*, *improvement* o *relapse*.

Pipeline: Flujo estructurado de procesamiento de datos, en este caso desde la descarga de abstracts hasta su análisis y visualización.

PubMed: Base de datos biomédica mantenida por la National Library of Medicine. Fuente principal de información en este trabajo.

RAG (Retrieval-Augmented Generation): Técnica híbrida que combina recuperación de documentos relevantes con generación de texto. Aplicada en el chatbot del sistema.

Red de co-ocurrencias: Representación en forma de grafo de las relaciones frecuentes entre entidades (por ejemplo, fármacos y outcomes) en el corpus de abstracts.

Sertralina: Antidepresivo ISRS utilizado como caso clínico principal en el análisis del TFM.

Streamlit: Framework de Python para desarrollar interfaces gráficas interactivas orientadas a ciencia de datos. Utilizado para construir la aplicación web del proyecto.

TF-IDF (Term Frequency - Inverse Document Frequency): Métrica utilizada para calcular la importancia relativa de un término en un documento dentro de un corpus. Base del análisis de frecuencias y clustering en este proyecto.

Wordcloud: Representación visual en forma de nube de palabras que muestra los términos más frecuentes en un conjunto de textos.

Tabla de acrónimos

Acrónimo	Significado
API	Application Programming Interface
BERT	Bidirectional Encoder Representations from Transformers
FAISS	Facebook AI Similarity Search
HAM-D	Hamilton Depression Rating Scale
ISRS	Inhibidores Selectivos de la Recaptación de Serotonina
NER	Named Entity Recognition
NLP	Natural Language Processing
PMID	PubMed Identifier
PLN	Procesamiento del Lenguaje Natural
QA	Question Answering
RAG	Retrieval-Augmented Generation
TF-IDF	Term Frequency - Inverse Document Frequency
UOC	Universitat Oberta de Catalunya

Cuadro 6.1: Tabla de acrónimos utilizados en el documento.

Bibliografía

- [1] World Health Organization. *Depression*. <https://www.who.int/news-room/fact-sheets/detail/depression>. 2021.
- [2] American Psychiatric Association. *Diagnostic and Statistical Manual of Mental Disorders (5th ed.)* Washington, DC: American Psychiatric Publishing, 2013.
- [3] Paul E. Greenberg et al. "The economic burden of adults with major depressive disorder in the United States (2005 and 2010)". En: *The Journal of Clinical Psychiatry* 76.2 (2015), págs. 155-162. DOI: 10.4088/JCP.14m09298.
- [4] Michael Bauer et al. "Prescribing patterns and treatment costs in patients with major depressive disorder: A 2-year prospective study in five European countries". En: *European Journal of Psychiatry* 22.2 (2008), págs. 69-79.
- [5] A John Rush et al. "Bupropion-SR, sertraline, or venlafaxine-XR after failure of SSRIs for depression". En: *New England Journal of Medicine* 354.12 (2006), págs. 1231-1242.
- [6] National Center for Biotechnology Information. *PubMed*. <https://pubmed.ncbi.nlm.nih.gov/>. 2022.
- [7] Aaron M Cohen y William R Hersh. "A survey of current work in biomedical text mining". En: *Briefings in bioinformatics* 6.1 (2006), págs. 57-71.
- [8] Nandini Jothi, N. A. Rashid y W. Husain. "Data mining in healthcare: A review". En: *Procedia Computer Science*. Vol. 72. 2015, págs. 306-313. DOI: 10.1016/j.procs.2015.12.145.
- [9] Jiho Lee et al. "BioBERT: A pre-trained biomedical language representation model for biomedical text mining". En: *Bioinformatics* 36.4 (2020), págs. 1234-1240. DOI: 10.1093/bioinformatics/btz682.
- [10] Yu Gu et al. *Domain-Specific Language Model Pretraining for Biomedical Natural Language Processing*. arXiv preprint arXiv:2007.15779. Trabajo donde se discute *BioMedBERT*. 2022.
- [11] United Nations. *Transforming our world: The 2030 Agenda for Sustainable Development*. <https://sdgs.un.org/2030agenda>. 2015.
- [12] Patrick Lewis et al. "Retrieval-augmented generation for knowledge-intensive nlp tasks". En: *Advances in neural information processing systems* 33 (2020), págs. 9459-9474.
- [13] Harrison Chase. *LangChain: Large Language Model Application Framework*. <https://github.com/hwchase17/langchain>. 2023.

- [14] Streamlit Inc. *Streamlit – The fastest way to build and share data apps*. <https://streamlit.io>. 2023.
- [15] Karen Sparck Jones. “Natural Language Processing: A Historical Review”. En: *Current Issues in Computational Linguistics: In Honour of Don Walker*. Ed. por Antonio Zampolli, Nicoletta Calzolari y Martha Palmer. Vol. 9–10. *Linguistica Computazionale*, 1994, págs. 3-16. URL: <https://aclanthology.org/www.mt-archive.info/Zampolli-1994-Sparck-Jones.pdf>.
- [16] Ruyi Luo et al. “BioGPT: Generative Pre-trained Transformer for Biomedical Text Generation and Mining”. En: *Briefings in Bioinformatics* 23.6 (2022). DOI: 10.1093/bib/bbac409. URL: <https://arxiv.org/abs/2210.10341>.
- [17] Jeff Johnson, Matthijs Douze y Hervé Jégou. “Billion-scale similarity search with GPUs”. En: *IEEE Transactions on Big Data* 7.3 (2019), págs. 535-547.
- [18] Zhiyong Lu. “PubMed and beyond: a survey of web tools for searching biomedical literature”. En: *Database* 2011 (2011), baq036. DOI: 10.1093/database/baq036.
- [19] Lawrence Hunter y Kevin B Cohen. “Biomedical language processing: what’s beyond PubMed?” En: *Molecular Cell* 21.5 (2006), págs. 589-594.
- [20] Dina Demner-Fushman y Jimmy Lin. “Information retrieval and natural language processing for biomedical literature”. En: *Bioinformatics* 25.3 (2009), págs. 321-328.
- [21] Yanshan et al. Wang. “Clinical information extraction applications: A literature review”. En: *Journal of biomedical informatics* 77 (2018), págs. 34-49.
- [22] Xiaoqian Jiang et al. “Biomedical literature mining for drug-related knowledge: a survey from the perspective of information retrieval and natural language processing”. En: *Drug Discovery Today* 21.3 (2016), págs. 454-462.
- [23] Qing Wang et al. “Text Mining for Precision Medicine: Applications and Challenges”. En: *Briefings in Bioinformatics* 20.3 (2019), págs. 804-814. DOI: 10.1093/bib/bby127.
- [24] Byung-Hak Yoon, Sung-Kwon Kim y Soo-Yong Kim. “Deep semantic mining for biomedical literature”. En: *BMC Bioinformatics* 22.1 (2021), págs. 1-15. DOI: 10.1186/s12859-021-04024-4.
- [25] Qian Chen, Alexis Allot y Zhiyong Lu. “LitCovid: an open database of COVID-19 literature”. En: *Nucleic Acids Research* 49.D1 (2021), págs. D1534-D1540. DOI: 10.1093/nar/gkaa952.
- [26] Emily Alsentzer et al. “Publicly Available Clinical BERT Embeddings”. En: *Proceedings of the 2nd Clinical Natural Language Processing Workshop* (2019), págs. 72-78. URL: <https://arxiv.org/abs/1904.03323>.
- [27] Karen Sparck Jones. “A statistical interpretation of term specificity and its application in retrieval”. En: *Journal of documentation* 28.1 (1972), págs. 11-21.
- [28] National Center for Biotechnology Information. *LitSense - Biomedical Semantic Search*. <https://www.ncbi.nlm.nih.gov/research/litsense/>. 2023.
- [29] Chen Chen et al. “iPubMed Explorer: An Interactive System for Biomedical Literature Search and Exploration”. En: *Journal of Biomedical Informatics* 119 (2021), pág. 103821. DOI: 10.1016/j.jbi.2021.103821.

- [30] Chih-Hsuan Wei et al. “PubTator Central: automated concept annotation for biomedical full text articles”. En: *Nucleic Acids Research* 47.W1 (2019), W587-W593. DOI: 10.1093/nar/gkz389.

Capítulo 7

Anexos

Documentación complementaria

Además de esta memoria, se ha elaborado documentación adicional disponible en el repositorio del proyecto, que incluye:

- Manual de instalación.
- Manual de usuario.
- Scripts de ejecución y carga de datos.

Todo el contenido puede consultarse en:

<https://github.com/alexdelgadoperibanez/TFMUOC-AlejandroDelgado>

Documento ejemplo de la base de datos

A continuación se muestra una entrada real de la base de datos MongoDB correspondiente al artículo con PMID 15927091. Este documento contiene el título, resumen, fecha, entidades extraídas mediante modelos NER y un resumen automático.

Listing 7.1: Ejemplo de documento almacenado en MongoDB

```

1 PubMedDB> db.major_depression_abstracts.findOne({"pmid": '15927091'})
2 {
3   _id: ObjectId("6802206030a48850b961b5ea"),
4   pmid: '15927091',
5   abstract: 'An acute-phase response (APR), manifested as an increase of acute-phase proteins has been shown in major
6     depression. Panic disorder (PD) may share some aetiopathogenic mechanisms with depression, but APR has not been studied
7     in this disorder. Forty-one panic patients in the first stages of their illness were compared with 32 healthy subjects
8     of comparable sex, age, and body mass index. Clinical diagnosis was established with the mini international
9     neuropsychiatric interview, and severity with the panic disorder severity scale and the CGI scale. Laboratory
10    determinations included four acute phase proteins (APPs) [albumin, gammaglobulins, fibrinogen, C-reactive-protein (CRP)
11    ] and basal cortisol level. Patients were studied after 8-wk follow-up taking selective serotonin reuptake inhibitors (
12    SSRIs) to assess the evolution of the APPs. Gammaglobulin levels were lower, and both cortisol and CRP levels were
13    higher in PD patients than in controls. APP did not differ between patients with or without agoraphobia. At follow-up,
14    patients who responded to SSRIs presented a decrease in albumin levels, and a trend towards a decrease in cortisol and
15    CRP compared with levels at intake. The conclusions of this study are that there is an APR in patients suffering from
16    PD, and this APR tends to diminish after a successful treatment with SSRIs.',
17   date: '2005 Dec',
18   title: 'The acute phase response in panic disorder.',
19   abstract1: 'An acute-phase response (APR), manifested as an increase of acute-phase proteins has been shown in major
20     depression. Panic disorder (PD) may share some aetiopathogenic mechanisms with depression, but APR has not been studied
21     in this disorder. Forty-one panic patients in the first stages of their illness were compared with 32 healthy subjects
22     of comparable sex, age, and body mass index. Clinical diagnosis was established with the mini international
23     neuropsychiatric interview, and severity with the panic disorder severity scale and the CGI scale. Laboratory
24     determinations included four acute phase proteins (APPs) [albumin, gammaglobulins, fibrinogen, C-reactive-protein (CRP)
25     ] and basal cortisol level. Patients were studied after 8-wk follow-up taking selective serotonin reuptake inhibitors (
26     SSRIs) to assess the evolution of the APPs. Gammaglobulin levels were lower, and both cortisol and CRP levels were
27     higher in PD patients than in controls. APP did not differ between patients with or without agoraphobia. At follow-up,
28     patients who responded to SSRIs presented a decrease in albumin levels, and a trend towards a decrease in cortisol and
29     CRP compared with levels at intake. The conclusions of this study are that there is an APR in patients suffering from
30     PD, and this APR tends to diminish after a successful treatment with SSRIs.',
31   abstract2: '',
32   entities: [
33     {
34       entity_group: 'protein',
35       word: 'acutephaseproteins',
36       occurrences: 1,
37       overall_combined_score: 0.9377796649932861,
38       models: [ 'judithrosell/JNLPBA_PubMedBERT_NER' ],
39       positions: [
40         {
41           start: 60,
42           end: 80,
43           score_sum: 0.9377796649932861,
44           count: 1,
45           combined_score: 0.9377796649932861,
46           models: [ 'judithrosell/JNLPBA_PubMedBERT_NER' ]
47         }
48       ]
49     },
50     {
51       entity_group: 'protein',
52       word: 'acutephaseproteins',
53       occurrences: 1,
54       overall_combined_score: 0.9611998200416565,
55       models: [ 'judithrosell/JNLPBA_PubMedBERT_NER' ],
56       positions: [
57         {
58           start: 591,
59           end: 611,
60           score_sum: 0.9611998200416565,
61           count: 1,
62           combined_score: 0.9611998200416565,
63           models: [ 'judithrosell/JNLPBA_PubMedBERT_NER' ]
64         }
65       ]
66     },
67     {
68       entity_group: 'protein',
69       word: 'apps',
70       occurrences: 2,
71       overall_combined_score: 0.9481932520866394,
72       models: [ 'judithrosell/JNLPBA_PubMedBERT_NER' ],
73       positions: [
74         {
75           start: 613,
76           end: 617,
77           score_sum: 0.9587461352348328,
78           count: 1,
79           combined_score: 0.9587461352348328,
80           models: [ 'judithrosell/JNLPBA_PubMedBERT_NER' ]
81         }
82       ]
83     }
84   ]
85 }

```

```

59     },
60     {
61         start: 838,
62         end: 842,
63         score_sum: 0.937640368938446,
64         count: 1,
65         combined_score: 0.937640368938446,
66         models: [ 'judithrosell/JNLPBA_PubMedBERT_NER' ]
67     }
68 ],
69 },
70 {
71     entity_group: 'protein',
72     word: 'albumin',
73     occurrences: 2,
74     overall_combined_score: 0.9410406053066254,
75     models: [ 'judithrosell/JNLPBA_PubMedBERT_NER' ],
76     positions: [
77         {
78             start: 620,
79             end: 627,
80             score_sum: 0.9685714244842529,
81             count: 1,
82             combined_score: 0.9685714244842529,
83             models: [ 'judithrosell/JNLPBA_PubMedBERT_NER' ]
84         },
85         {
86             start: 1090,
87             end: 1097,
88             score_sum: 0.9135097861289978,
89             count: 1,
90             combined_score: 0.9135097861289978,
91             models: [ 'judithrosell/JNLPBA_PubMedBERT_NER' ]
92         }
93     ]
94 },
95 {
96     entity_group: 'protein',
97     word: 'gammaglobulins',
98     occurrences: 1,
99     overall_combined_score: 0.9659823775291443,
100    models: [ 'judithrosell/JNLPBA_PubMedBERT_NER' ],
101    positions: [
102        {
103            start: 629,
104            end: 643,
105            score_sum: 0.9659823775291443,
106            count: 1,
107            combined_score: 0.9659823775291443,
108            models: [ 'judithrosell/JNLPBA_PubMedBERT_NER' ]
109        }
110    ]
111 },
112 {
113     entity_group: 'protein',
114     word: 'fibrinogen',
115     occurrences: 1,
116     overall_combined_score: 0.9708130359649658,
117     models: [ 'judithrosell/JNLPBA_PubMedBERT_NER' ],
118     positions: [
119         {
120             start: 645,
121             end: 655,
122             score_sum: 0.9708130359649658,
123             count: 1,
124             combined_score: 0.9708130359649658,
125             models: [ 'judithrosell/JNLPBA_PubMedBERT_NER' ]
126         }
127     ]
128 },
129 {
130     entity_group: 'protein',
131     word: 'creactiveprotein',
132     occurrences: 1,
133     overall_combined_score: 0.9398608207702637,
134     models: [ 'judithrosell/JNLPBA_PubMedBERT_NER' ],
135     positions: [
136         {
137             start: 657,
138             end: 675,
139             score_sum: 0.9398608207702637,
140             count: 1,
141             combined_score: 0.9398608207702637,
142             models: [ 'judithrosell/JNLPBA_PubMedBERT_NER' ]
143         }
144     ]
145 },
146 {
147     entity_group: 'protein',
148     word: 'crp',
149     occurrences: 3,
150     overall_combined_score: 0.8460968732833862,

```

```

151 models: [ 'judithrosell/JNLPBA_PubMedBERT_NER' ],
152 positions: [
153   {
154     start: 677,
155     end: 680,
156     score_sum: 0.9722860455513,
157     count: 1,
158     combined_score: 0.9722860455513,
159     models: [ 'judithrosell/JNLPBA_PubMedBERT_NER' ]
160   },
161   {
162     start: 899,
163     end: 902,
164     score_sum: 0.6976471543312073,
165     count: 1,
166     combined_score: 0.6976471543312073,
167     models: [ 'judithrosell/JNLPBA_PubMedBERT_NER' ]
168   },
169   {
170     start: 1153,
171     end: 1156,
172     score_sum: 0.8683574199676514,
173     count: 1,
174     combined_score: 0.8683574199676514,
175     models: [ 'judithrosell/JNLPBA_PubMedBERT_NER' ]
176   }
177 ],
178 },
179 {
180   entity_group: 'protein',
181   word: 'gammaglobulin',
182   occurrences: 1,
183   overall_combined_score: 0.9400185942649841,
184   models: [ 'judithrosell/JNLPBA_PubMedBERT_NER' ],
185   positions: [
186     {
187       start: 844,
188       end: 857,
189       score_sum: 0.9400185942649841,
190       count: 1,
191       combined_score: 0.9400185942649841,
192       models: [ 'judithrosell/JNLPBA_PubMedBERT_NER' ]
193     }
194   ]
195 },
196 {
197   entity_group: 'protein',
198   word: 'app',
199   occurrences: 1,
200   overall_combined_score: 0.9053472280502319,
201   models: [ 'judithrosell/JNLPBA_PubMedBERT_NER' ],
202   positions: [
203     {
204       start: 955,
205       end: 958,
206       score_sum: 0.9053472280502319,
207       count: 1,
208       combined_score: 0.9053472280502319,
209       models: [ 'judithrosell/JNLPBA_PubMedBERT_NER' ]
210     }
211   ]
212 },
213 {
214   entity_group: 'Disease',
215   word: 'majordepression',
216   occurrences: 1,
217   overall_combined_score: 0.9741801023483276,
218   models: [ 'judithrosell/BC5CDR_PubMedBERT_NER' ],
219   positions: [
220     {
221       start: 99,
222       end: 115,
223       score_sum: 0.9741801023483276,
224       count: 1,
225       combined_score: 0.9741801023483276,
226       models: [ 'judithrosell/BC5CDR_PubMedBERT_NER' ]
227     }
228   ]
229 },
230 {
231   entity_group: 'Disease',
232   word: 'panicdisorder',
233   occurrences: 2,
234   overall_combined_score: 0.9878618121147156,
235   models: [ 'judithrosell/BC5CDR_PubMedBERT_NER' ],
236   positions: [
237     {
238       start: 117,
239       end: 131,
240       score_sum: 0.9882774353027344,
241       count: 1,
242       combined_score: 0.9882774353027344,

```

```

243     models: [ 'judithrosell/BC5CDR_PubMedBERT_NER' ]
244   },
245   {
246     start: 502,
247     end: 516,
248     score_sum: 0.9874461889266968,
249     count: 1,
250     combined_score: 0.9874461889266968,
251     models: [ 'judithrosell/BC5CDR_PubMedBERT_NER' ]
252   }
253 ]
254 },
255 {
256   entity_group: 'Disease',
257   word: null,
258   occurrences: 3,
259   overall_combined_score: 0.9851487874984741,
260   models: [ 'judithrosell/BC5CDR_PubMedBERT_NER' ],
261   positions: [
262     {
263       start: 133,
264       end: 135,
265       score_sum: 0.9855985045433044,
266       count: 1,
267       combined_score: 0.9855985045433044,
268       models: [ 'judithrosell/BC5CDR_PubMedBERT_NER' ]
269     },
270     {
271       start: 925,
272       end: 927,
273       score_sum: 0.9847032427787781,
274       count: 1,
275       combined_score: 0.9847032427787781,
276       models: [ 'judithrosell/BC5CDR_PubMedBERT_NER' ]
277     },
278     {
279       start: 1271,
280       end: 1273,
281       score_sum: 0.9851446151733398,
282       count: 1,
283       combined_score: 0.9851446151733398,
284       models: [ 'judithrosell/BC5CDR_PubMedBERT_NER' ]
285     }
286   ]
287 },
288 {
289   entity_group: 'Disease',
290   word: 'depression',
291   occurrences: 1,
292   overall_combined_score: 0.988921046257019,
293   models: [ 'judithrosell/BC5CDR_PubMedBERT_NER' ],
294   positions: [
295     {
296       start: 184,
297       end: 194,
298       score_sum: 0.988921046257019,
299       count: 1,
300       combined_score: 0.988921046257019,
301       models: [ 'judithrosell/BC5CDR_PubMedBERT_NER' ]
302     }
303   ]
304 },
305 {
306   entity_group: 'Disease',
307   word: 'panic',
308   occurrences: 1,
309   overall_combined_score: 0.9881533980369568,
310   models: [ 'judithrosell/BC5CDR_PubMedBERT_NER' ],
311   positions: [
312     {
313       start: 253,
314       end: 258,
315       score_sum: 0.9881533980369568,
316       count: 1,
317       combined_score: 0.9881533980369568,
318       models: [ 'judithrosell/BC5CDR_PubMedBERT_NER' ]
319     }
320   ]
321 },
322 {
323   entity_group: 'Chemical',
324   word: 'selectiveserotoninreuptakeinhibitors',
325   occurrences: 1,
326   overall_combined_score: 0.9413002729415894,
327   models: [ 'judithrosell/BC5CDR_PubMedBERT_NER' ],
328   positions: [
329     {
330       start: 759,
331       end: 798,
332       score_sum: 0.9413002729415894,
333       count: 1,
334       combined_score: 0.9413002729415894,

```

```

335     models: [ 'judithrosell/BC5CDR_PubMedBERT_NER' ]
336   }
337 ]
338 },
339 {
340   entity_group: 'Chemical',
341   word: 'ssris',
342   occurrences: 3,
343   overall_combined_score: 0.8757796088854471,
344   models: [ 'judithrosell/BC5CDR_PubMedBERT_NER' ],
345   positions: [
346     {
347       start: 800,
348       end: 805,
349       score_sum: 0.8356923460960388,
350       count: 1,
351       combined_score: 0.8356923460960388,
352       models: [ 'judithrosell/BC5CDR_PubMedBERT_NER' ]
353     },
354     {
355       start: 1060,
356       end: 1065,
357       score_sum: 0.9172472953796387,
358       count: 1,
359       combined_score: 0.9172472953796387,
360       models: [ 'judithrosell/BC5CDR_PubMedBERT_NER' ]
361     },
362     {
363       start: 1340,
364       end: 1345,
365       score_sum: 0.8743991851806641,
366       count: 1,
367       combined_score: 0.8743991851806641,
368       models: [ 'judithrosell/BC5CDR_PubMedBERT_NER' ]
369     }
370   ]
371 },
372 {
373   entity_group: 'Disease',
374   word: 'agoraphobia',
375   occurrences: 1,
376   overall_combined_score: 0.9426554441452026,
377   models: [ 'judithrosell/BC5CDR_PubMedBERT_NER' ],
378   positions: [
379     {
380       start: 1007,
381       end: 1018,
382       score_sum: 0.9426554441452026,
383       count: 1,
384       combined_score: 0.9426554441452026,
385       models: [ 'judithrosell/BC5CDR_PubMedBERT_NER' ]
386     }
387   ]
388 },
389 {
390   entity_group: 'Organism',
391   word: 'subjects',
392   occurrences: 1,
393   overall_combined_score: 0.662304699420929,
394   models: [ 'judithrosell/BioNLP13CG_PubMedBERT_NER' ],
395   positions: [
396     {
397       start: 335,
398       end: 343,
399       score_sum: 0.662304699420929,
400       count: 1,
401       combined_score: 0.662304699420929,
402       models: [ 'judithrosell/BioNLP13CG_PubMedBERT_NER' ]
403     }
404   ]
405 },
406 {
407   entity_group: 'Gene_or_gene_product',
408   word: 'albumin',
409   occurrences: 2,
410   overall_combined_score: 0.9539275765419006,
411   models: [ 'judithrosell/BioNLP13CG_PubMedBERT_NER' ],
412   positions: [
413     {
414       start: 620,
415       end: 627,
416       score_sum: 0.963663637638092,
417       count: 1,
418       combined_score: 0.963663637638092,
419       models: [ 'judithrosell/BioNLP13CG_PubMedBERT_NER' ]
420     },
421     {
422       start: 1090,
423       end: 1097,
424       score_sum: 0.9441915154457092,
425       count: 1,
426       combined_score: 0.9441915154457092,

```

```

427     models: [ 'judithrosell/BioNLP13CG_PubMedBERT_NER' ]
428   }
429 ]
430 },
431 {
432   entity_group: 'Gene_or_gene_product',
433   word: 'gammaglobulins',
434   occurrences: 1,
435   overall_combined_score: 0.9365159869194031,
436   models: [ 'judithrosell/BioNLP13CG_PubMedBERT_NER' ],
437   positions: [
438     {
439       start: 629,
440       end: 643,
441       score_sum: 0.9365159869194031,
442       count: 1,
443       combined_score: 0.9365159869194031,
444       models: [ 'judithrosell/BioNLP13CG_PubMedBERT_NER' ]
445     }
446   ]
447 },
448 {
449   entity_group: 'Gene_or_gene_product',
450   word: 'fibrinogen',
451   occurrences: 1,
452   overall_combined_score: 0.9676080346107483,
453   models: [ 'judithrosell/BioNLP13CG_PubMedBERT_NER' ],
454   positions: [
455     {
456       start: 645,
457       end: 655,
458       score_sum: 0.9676080346107483,
459       count: 1,
460       combined_score: 0.9676080346107483,
461       models: [ 'judithrosell/BioNLP13CG_PubMedBERT_NER' ]
462     }
463   ]
464 },
465 {
466   entity_group: 'Gene_or_gene_product',
467   word: 'creactiveprotein',
468   occurrences: 1,
469   overall_combined_score: 0.9588044285774231,
470   models: [ 'judithrosell/BioNLP13CG_PubMedBERT_NER' ],
471   positions: [
472     {
473       start: 657,
474       end: 675,
475       score_sum: 0.9588044285774231,
476       count: 1,
477       combined_score: 0.9588044285774231,
478       models: [ 'judithrosell/BioNLP13CG_PubMedBERT_NER' ]
479     }
480   ]
481 },
482 {
483   entity_group: 'Gene_or_gene_product',
484   word: 'crp',
485   occurrences: 3,
486   overall_combined_score: 0.9516064922014872,
487   models: [ 'judithrosell/BioNLP13CG_PubMedBERT_NER' ],
488   positions: [
489     {
490       start: 677,
491       end: 680,
492       score_sum: 0.960913896560669,
493       count: 1,
494       combined_score: 0.960913896560669,
495       models: [ 'judithrosell/BioNLP13CG_PubMedBERT_NER' ]
496     },
497     {
498       start: 899,
499       end: 902,
500       score_sum: 0.9520710110664368,
501       count: 1,
502       combined_score: 0.9520710110664368,
503       models: [ 'judithrosell/BioNLP13CG_PubMedBERT_NER' ]
504     },
505     {
506       start: 1153,
507       end: 1156,
508       score_sum: 0.941834568977356,
509       count: 1,
510       combined_score: 0.941834568977356,
511       models: [ 'judithrosell/BioNLP13CG_PubMedBERT_NER' ]
512     }
513   ]
514 },
515 {
516   entity_group: 'Gene_or_gene_product',
517   word: 'cortisol',
518   occurrences: 3,

```

```

519 overall_combined_score: 0.8894089460372925,
520 models: [ 'judithrosell/BioNLP13CG_PubMedBERT_NER' ],
521 positions: [
522   {
523     start: 693,
524     end: 701,
525     score_sum: 0.8614456653594971,
526     count: 1,
527     combined_score: 0.8614456653594971,
528     models: [ 'judithrosell/BioNLP13CG_PubMedBERT_NER' ]
529   },
530   {
531     start: 886,
532     end: 894,
533     score_sum: 0.9147500395774841,
534     count: 1,
535     combined_score: 0.9147500395774841,
536     models: [ 'judithrosell/BioNLP13CG_PubMedBERT_NER' ]
537   },
538   {
539     start: 1140,
540     end: 1148,
541     score_sum: 0.8920311331748962,
542     count: 1,
543     combined_score: 0.8920311331748962,
544     models: [ 'judithrosell/BioNLP13CG_PubMedBERT_NER' ]
545   }
546 ]
547 },
548 {
549   entity_group: 'Organism',
550   word: 'patients',
551   occurrences: 4,
552   overall_combined_score: 0.7647702693939209,
553   models: [ 'judithrosell/BioNLP13CG_PubMedBERT_NER' ],
554   positions: [
555     {
556       start: 709,
557       end: 717,
558       score_sum: 0.7788323163986206,
559       count: 1,
560       combined_score: 0.7788323163986206,
561       models: [ 'judithrosell/BioNLP13CG_PubMedBERT_NER' ]
562     },
563     {
564       start: 982,
565       end: 990,
566       score_sum: 0.7528705596923828,
567       count: 1,
568       combined_score: 0.7528705596923828,
569       models: [ 'judithrosell/BioNLP13CG_PubMedBERT_NER' ]
570     },
571     {
572       start: 1034,
573       end: 1042,
574       score_sum: 0.7579254508018494,
575       count: 1,
576       combined_score: 0.7579254508018494,
577       models: [ 'judithrosell/BioNLP13CG_PubMedBERT_NER' ]
578     },
579     {
580       start: 1247,
581       end: 1255,
582       score_sum: 0.7694527506828308,
583       count: 1,
584       combined_score: 0.7694527506828308,
585       models: [ 'judithrosell/BioNLP13CG_PubMedBERT_NER' ]
586     }
587   ]
588 },
589 {
590   entity_group: 'Simple_chemical',
591   word: 'selectiveserotoninreuptakeinhibitors',
592   occurrences: 1,
593   overall_combined_score: 0.7112107276916504,
594   models: [ 'judithrosell/BioNLP13CG_PubMedBERT_NER' ],
595   positions: [
596     {
597       start: 759,
598       end: 798,
599       score_sum: 0.7112107276916504,
600       count: 1,
601       combined_score: 0.7112107276916504,
602       models: [ 'judithrosell/BioNLP13CG_PubMedBERT_NER' ]
603     }
604   ]
605 },
606 {
607   entity_group: 'Simple_chemical',
608   word: 'ssris',
609   occurrences: 3,
610   overall_combined_score: 0.7235044240951538,

```



```

611 models: [ 'judithrosell/BioNLP13CG_PubMedBERT_NER' ],
612 positions: [
613   {
614     start: 800,
615     end: 805,
616     score_sum: 0.7102763056755066,
617     count: 1,
618     combined_score: 0.7102763056755066,
619     models: [ 'judithrosell/BioNLP13CG_PubMedBERT_NER' ]
620   },
621   {
622     start: 1060,
623     end: 1065,
624     score_sum: 0.7580840587615967,
625     count: 1,
626     combined_score: 0.7580840587615967,
627     models: [ 'judithrosell/BioNLP13CG_PubMedBERT_NER' ]
628   },
629   {
630     start: 1340,
631     end: 1345,
632     score_sum: 0.7021529078483582,
633     count: 1,
634     combined_score: 0.7021529078483582,
635     models: [ 'judithrosell/BioNLP13CG_PubMedBERT_NER' ]
636   }
637 ],
638 },
639 {
640   entity_group: 'Gene_or_gene_product',
641   word: 'gammaglobulin',
642   occurrences: 1,
643   overall_combined_score: 0.9445821046829224,
644   models: [ 'judithrosell/BioNLP13CG_PubMedBERT_NER' ],
645   positions: [
646     {
647       start: 844,
648       end: 857,
649       score_sum: 0.9445821046829224,
650       count: 1,
651       combined_score: 0.9445821046829224,
652       models: [ 'judithrosell/BioNLP13CG_PubMedBERT_NER' ]
653     }
654   ],
655 },
656 {
657   entity_group: 'Gene_or_gene_product',
658   word: 'app',
659   occurrences: 1,
660   overall_combined_score: 0.8781405687332153,
661   models: [ 'judithrosell/BioNLP13CG_PubMedBERT_NER' ],
662   positions: [
663     {
664       start: 955,
665       end: 958,
666       score_sum: 0.8781405687332153,
667       count: 1,
668       combined_score: 0.8781405687332153,
669       models: [ 'judithrosell/BioNLP13CG_PubMedBERT_NER' ]
670     }
671   ],
672 },
673 ],
674 processed: [
675   [
676     'acutephase', 'response',
677     'apr', 'manifested',
678     'increase', 'acutephase',
679     'proteins', 'shown',
680     'major', 'depression'
681   ],
682   [
683     'panic',
684     'disorder',
685     'share',
686     'aetiopathogenic',
687     'mechanisms',
688     'depression',
689     'apr',
690     'studied',
691     'disorder'
692   ],
693   [
694     'fortyone', 'panic',
695     'patients', 'stages',
696     'illness', 'compared',
697     'healthy', 'subjects',
698     'comparable', 'sex',
699     'age', 'body',
700     'mass', 'index'
701   ],
702 ]

```

```

703      'clinical',      'diagnosis',
704      'established',  'mini',
705      'international', 'neuropsychiatric',
706      'interview',    'severity',
707      'panic',        'disorder',
708      'severity',      'scale',
709      'cgi',           'scale'
710    ],
711    [
712      'laboratory',    'determinations',
713      'included',      'acute',
714      'phase',         'proteins',
715      'apps',          'albumin',
716      'gammaglobulins', 'fibrinogen',
717      'creactiveprotein', 'crp',
718      'basal',         'cortisol',
719      'level'
720    ],
721    [
722      'patients',      'studied',
723      '8wk',           'followup',
724      'taking',         'selective',
725      'serotonin',     'reuptake',
726      'inhibitors',    'ssris',
727      'assess',        'evolution',
728      'apps'
729    ],
730    [
731      'gammaglobulin',
732      'levels',
733      'lower',
734      'cortisol',
735      'crp',
736      'levels',
737      'higher',
738      'patients',
739      'controls'
740    ],
741    [ 'app', 'differ', 'patients', 'agoraphobia' ],
742    [
743      'followup', 'patients',
744      'responded', 'ssris',
745      'presented', 'decrease',
746      'albumin',  'levels',
747      'trend',    'decrease',
748      'cortisol', 'crp',
749      'compared', 'levels',
750      'intake'
751    ],
752    [
753      'conclusions', 'study',
754      'apr',          'patients',
755      'suffering',    'apr',
756      'tends',        'diminish',
757      'successful',   'treatment',
758      'ssris'
759    ]
760  ],
761  summary: ' Panic disorder (PD) may share some aetiopathogenic mechanisms with depression, but APR has not been studied in
           this disorder . Patients who responded to SSRIs presented a decrease in albumin levels, and a trend towards a
           decreasing in cortisol and CRP .'
762 }

```

Diagrama de Gantt

